
RESIDÊNCIA
INTELIGÊNCIA ARTIFICIAL
FIESC
UniSENAI
INSTITUTO SENAI DE TECNOLOGIA
INSTITUTO SENAI DE INOVAÇÃO

RESIDÊNCIA INTELIGÊNCIA ARTIFICIAL

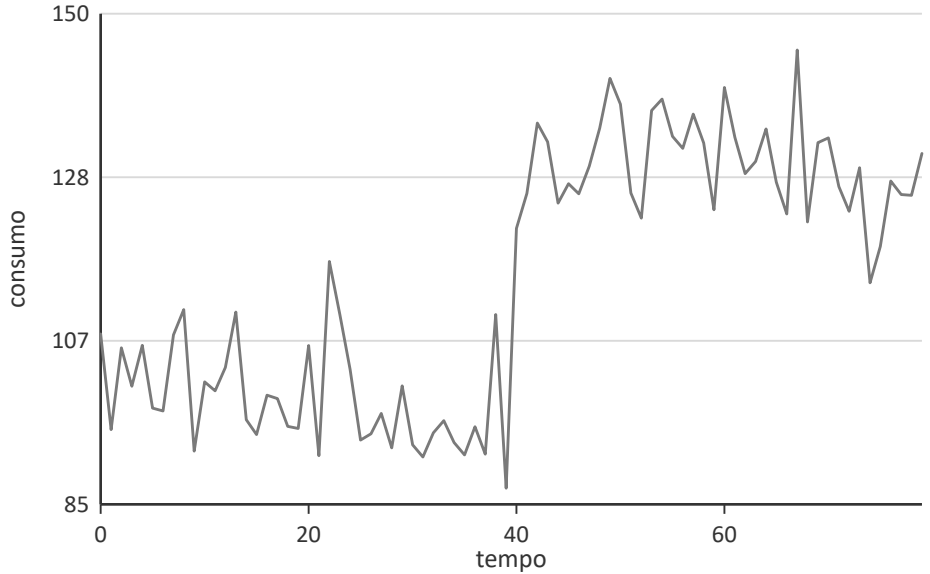
FIESC UniSENAI INSTITUTO SENAI DE TECNOLOGIA INSTITUTO SENAI DE INOVAÇÃO

Aula 3
Modelos AR, MA e ARMA

Prof. Matheus Vanzan

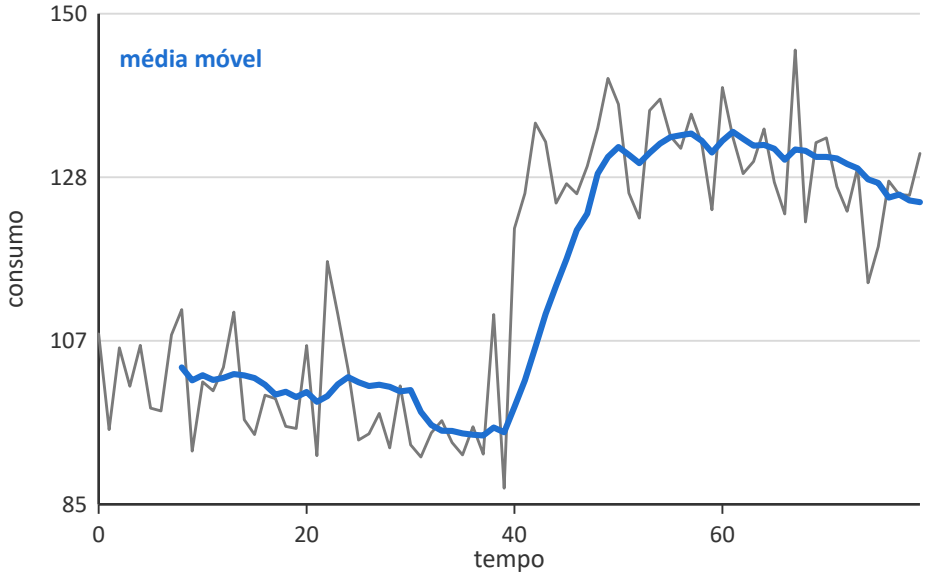
Séries Temporais

Revisão: suavização



Revisão: suavização

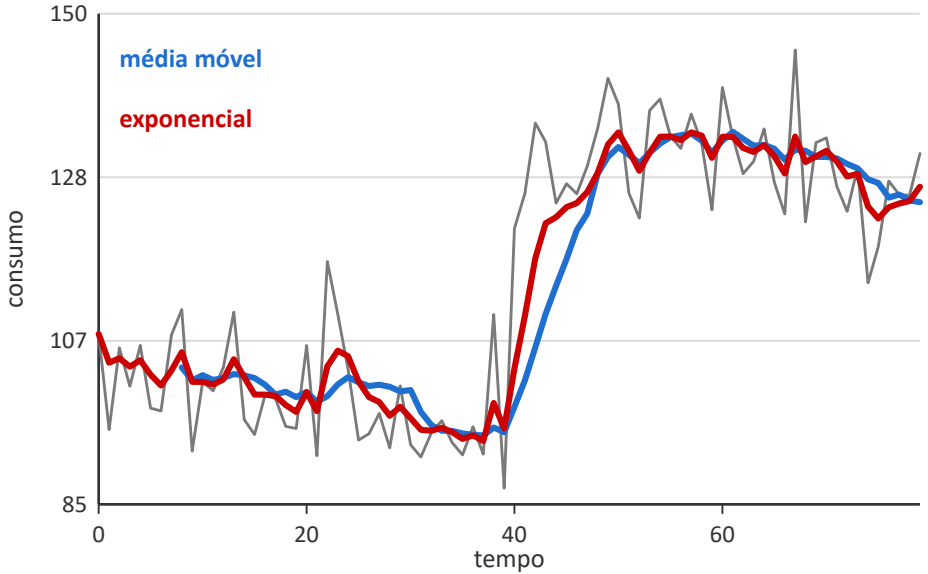
➡️ **Média móvel**: média dos k últimos valores, todos com o mesmo peso



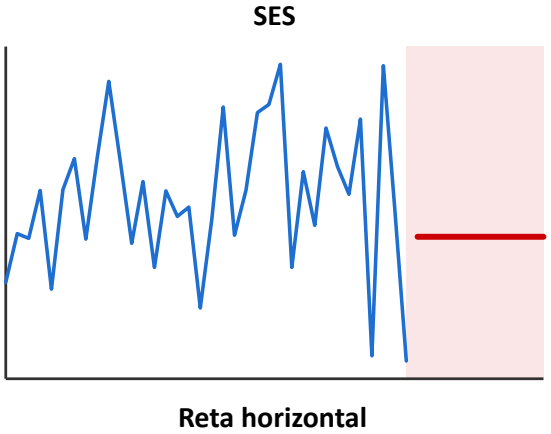
Revisão: suavização

➡️ **Média móvel**: média dos k últimos valores, todos com o mesmo peso

➡️ **Exponencial**: pesos que caem com o tempo, controlados por **α**

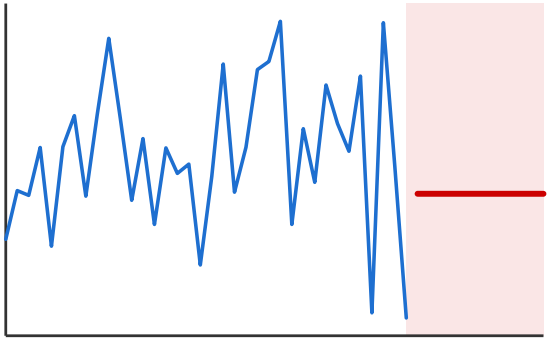


Revisão: previsão



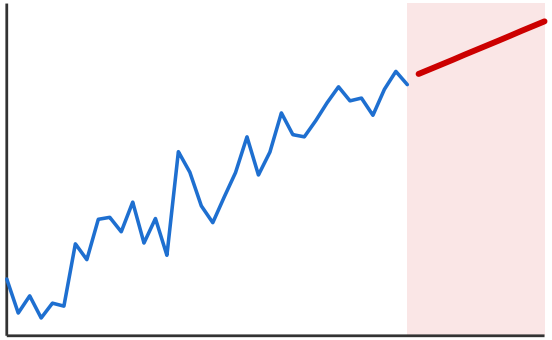
Revisão: previsão

SES



Reta horizontal

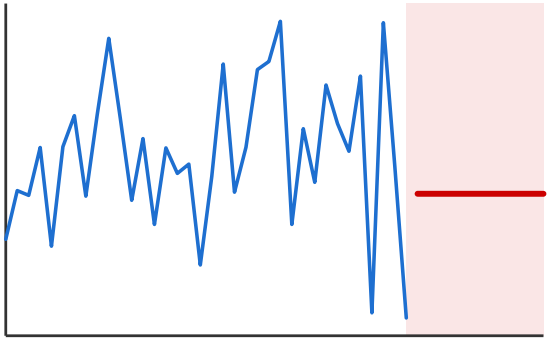
Holt



Reta inclinada

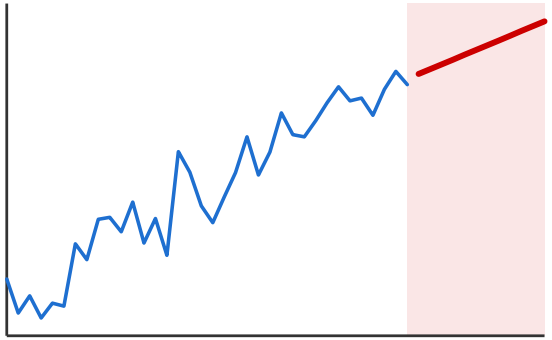
Revisão: previsão

SES



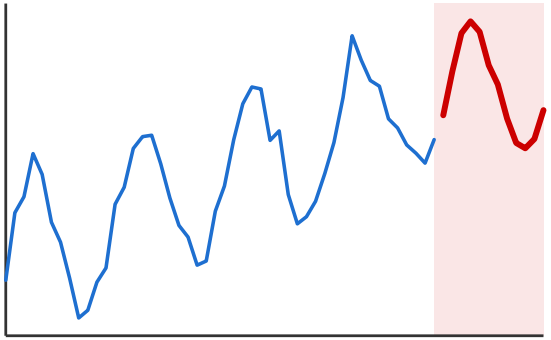
Reta horizontal

Holt



Reta inclinada

Holt-Winters



Acompanha a sazonalidade

Objetivos da aula

➡️ Modelo **AR** (autorregressivo)

Objetivos da aula

➡️ Modelo **AR** (autorregressivo)

➡️ Modelo **MA** (médias móveis)

Objetivos da aula

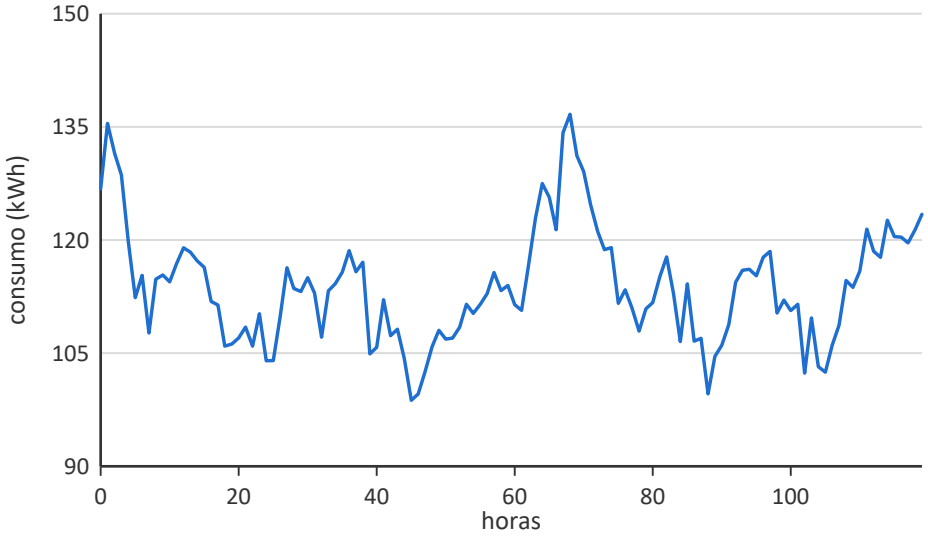
➡️ Modelo **AR** (autorregressivo)

➡️ Modelo **MA** (médias móveis)

➡️ Modelo **ARMA**: a combinação dos dois modelos anteriores

Nosso exemplo: consumo de energia

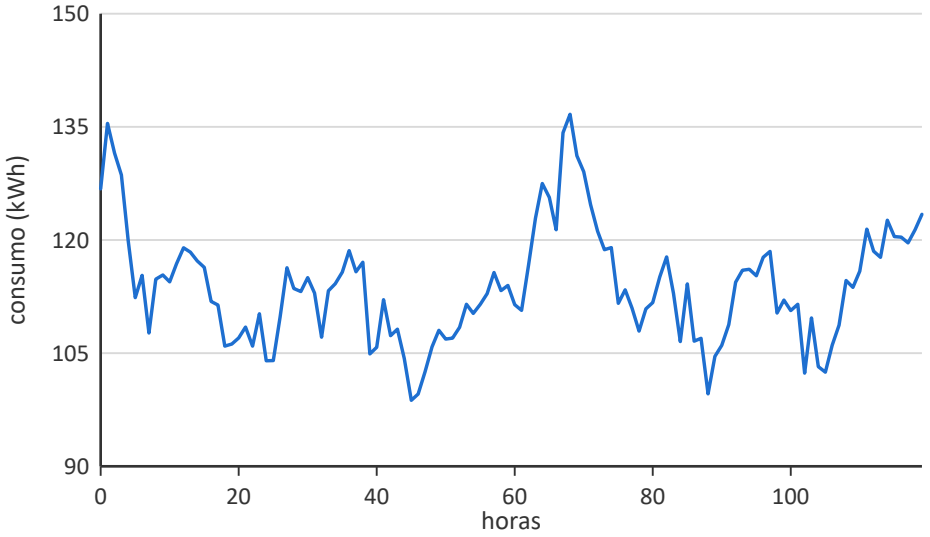
➡️ Uma fábrica, com o consumo de energia elétrica medido a cada **hora**



Nosso exemplo: consumo de energia

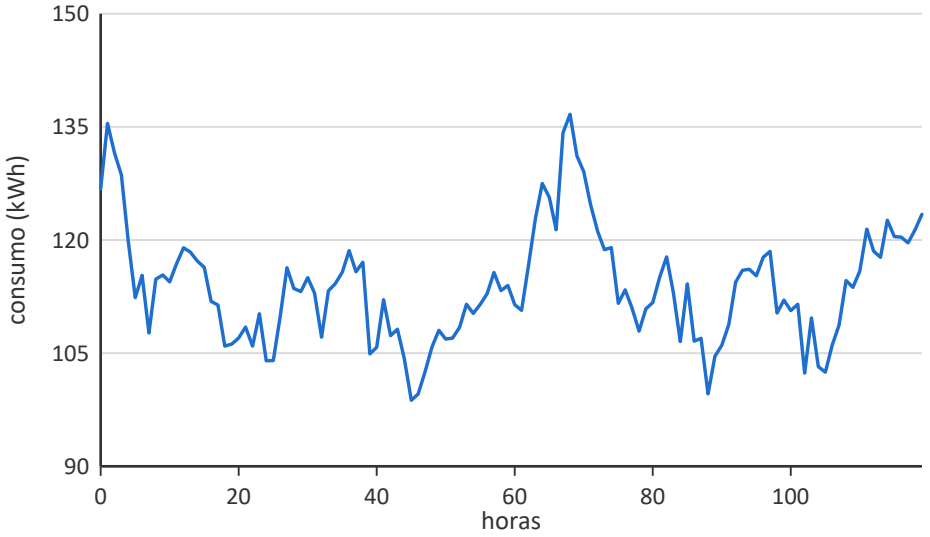
➡️ Uma fábrica, com o consumo de energia elétrica medido a cada **hora**

➡️ A pergunta: quanto a fábrica vai consumir nas **próximas horas**?



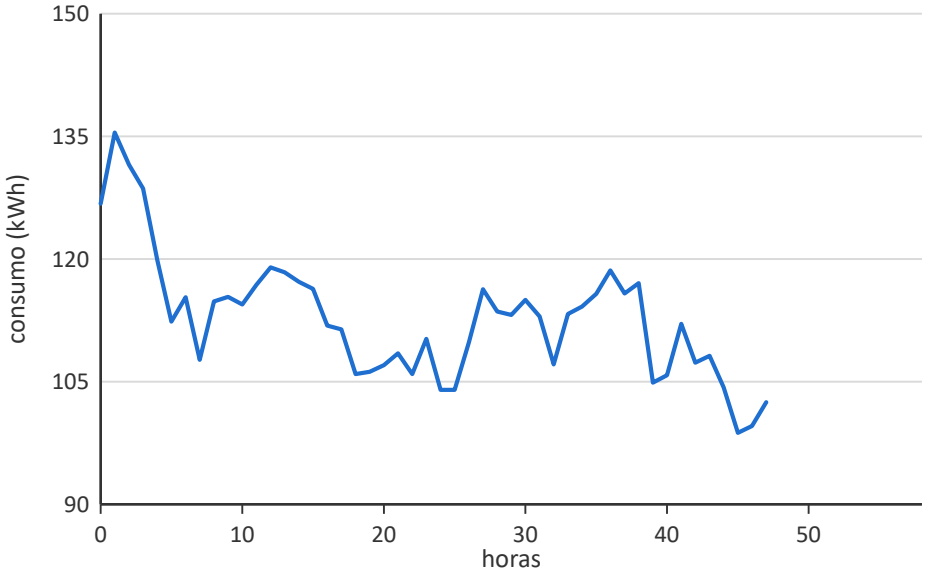
Nosso exemplo: consumo de energia

- ➡️ Uma fábrica, com o consumo de energia elétrica medido a cada **hora**
- ➡️ A pergunta: quanto a fábrica vai consumir nas **próximas horas**?
- ➡️ O consumo de agora se parece com o da hora anterior: o **passado da própria série** ajuda a prever



Defasagem (lag)

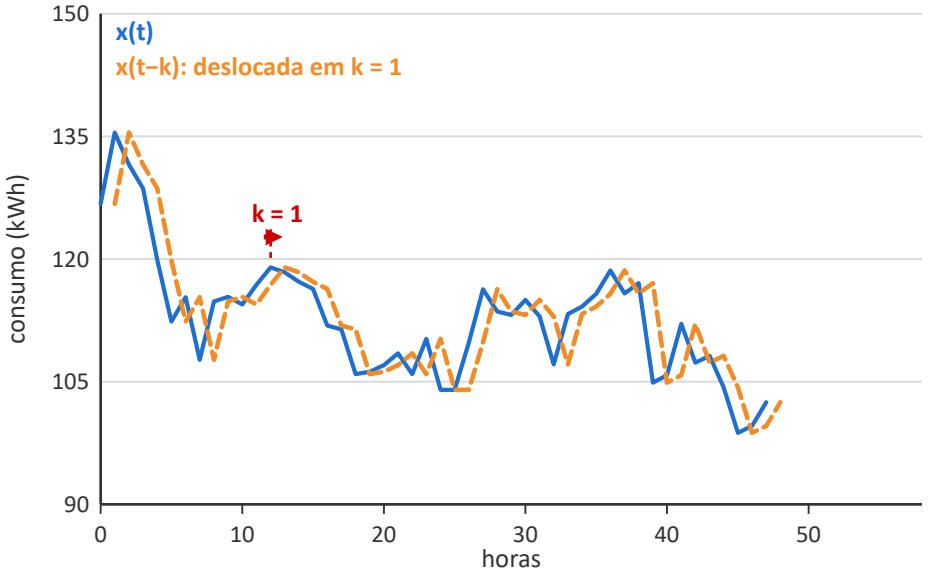
➡️ **Lag** k: deslocar a série k períodos para trás



Defasagem (lag)

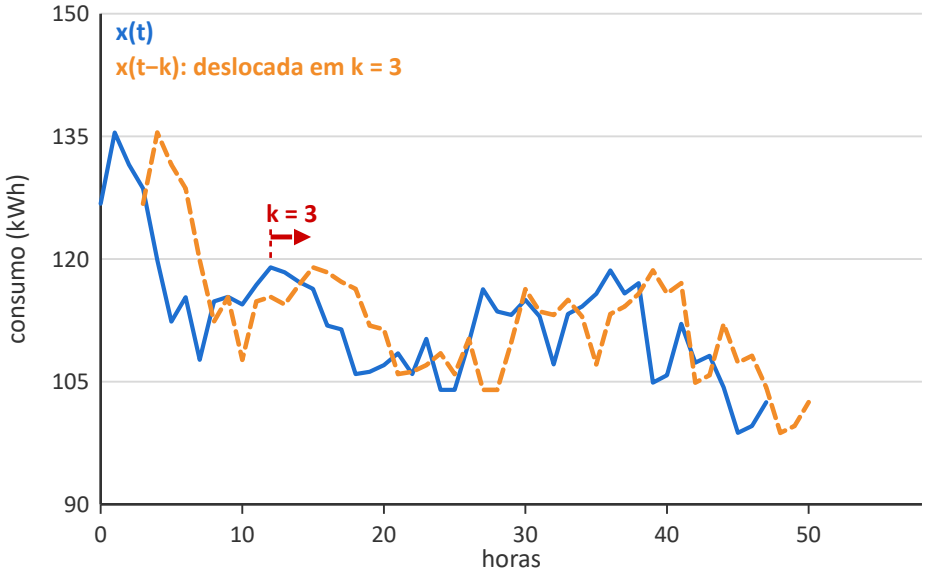
➡️ **Lag** k: deslocar a série k períodos para trás

➡️ Lag 1: o valor de 1 hora atrás, x_{t-1}



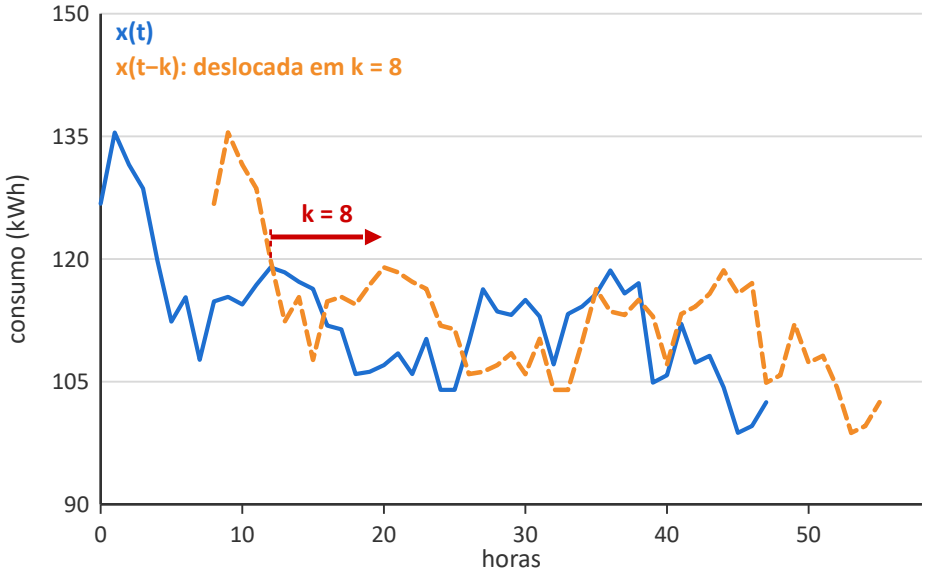
Defasagem (lag)

- **Lag** k: deslocar a série k períodos para trás
- Lag 1: o valor de 1 hora atrás, x_{t-1}
- Lag 3: o valor de 3 horas atrás, x_{t-3}



Defasagem (lag)

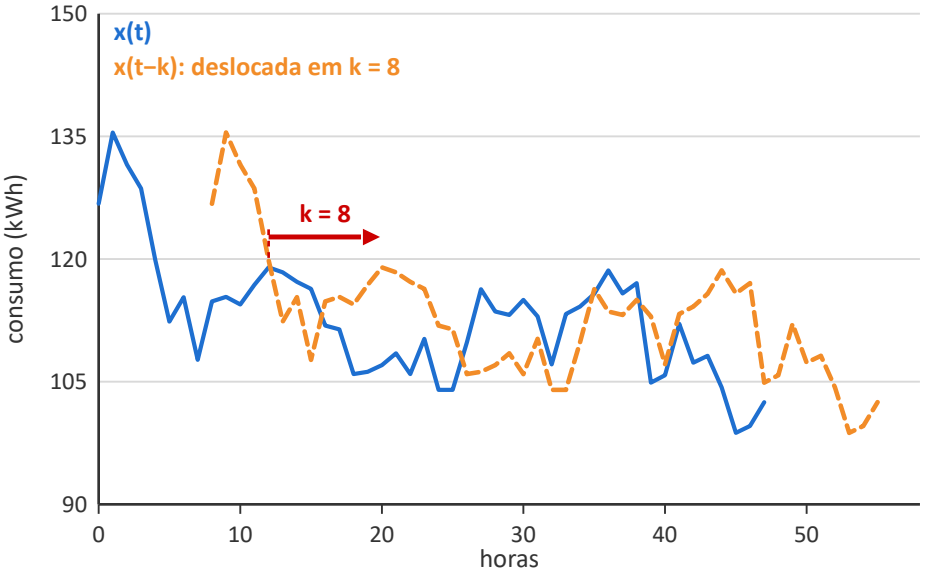
- **Lag** k: deslocar a série k períodos para trás
- Lag 1: o valor de 1 hora atrás, x_{t-1}
- Lag 3: o valor de 3 horas atrás, x_{t-3}
- Lag 8: o valor de 8 horas atrás, x_{t-8}



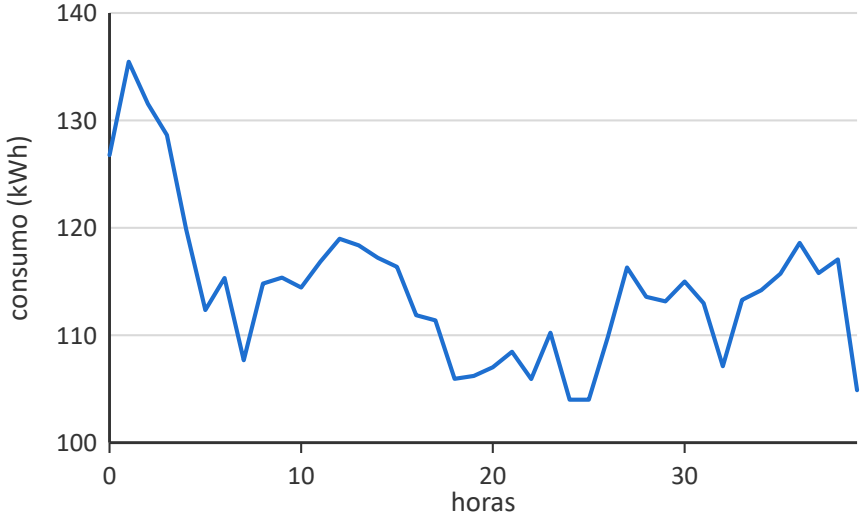
Defasagem (lag)

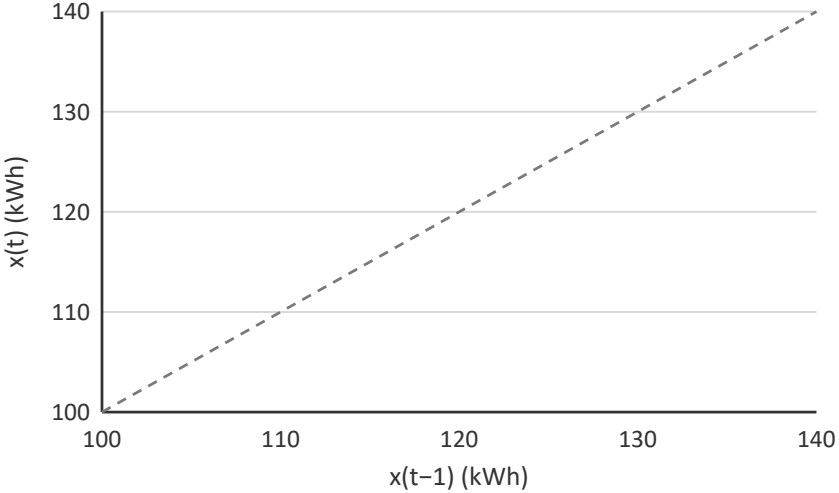
- **Lag** k: deslocar a série k períodos para trás
- Lag 1: o valor de 1 hora atrás, x_{t-1}
- Lag 3: o valor de 3 horas atrás, x_{t-3}
- Lag 8: o valor de 8 horas atrás, x_{t-8}

> A pergunta: x_t se parece com x_{t-k}?

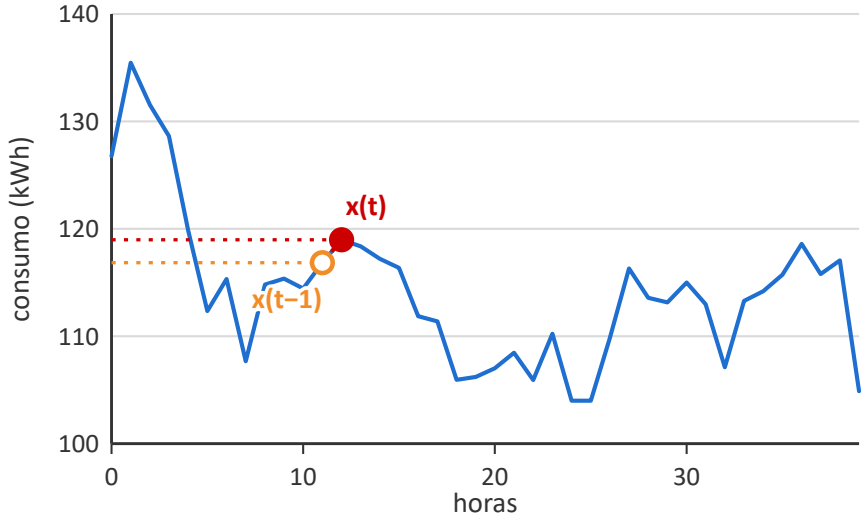


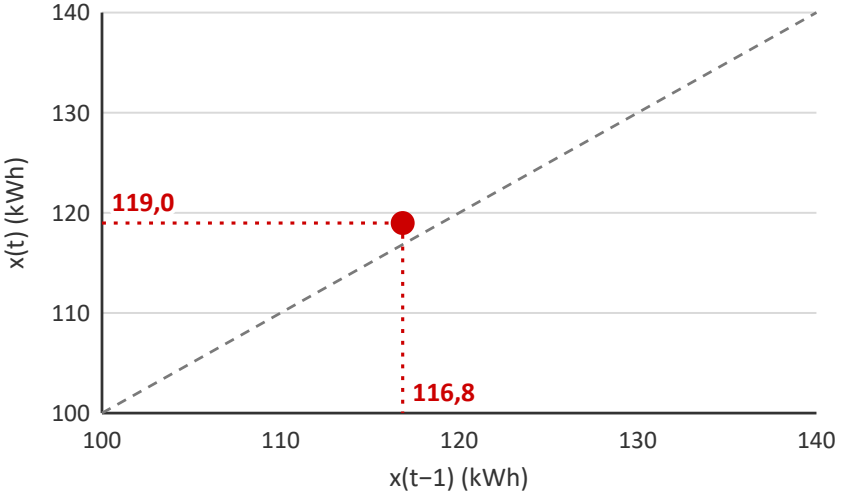
Defasagem e dispersão





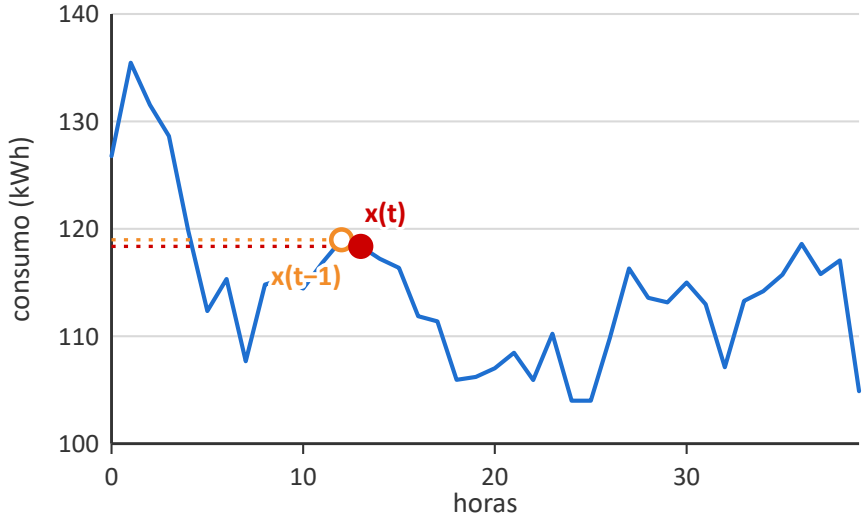
Defasagem e dispersão

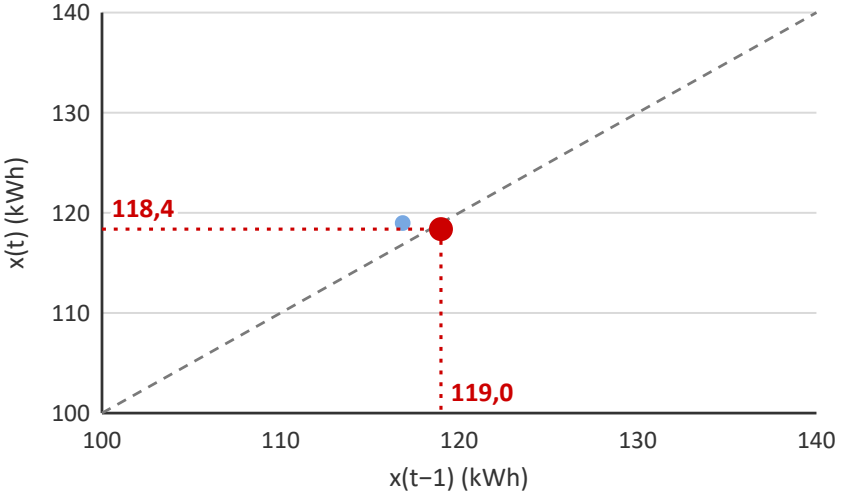




O par (x_{t-1}, x_t) vira um ponto: a leitura e a anterior.

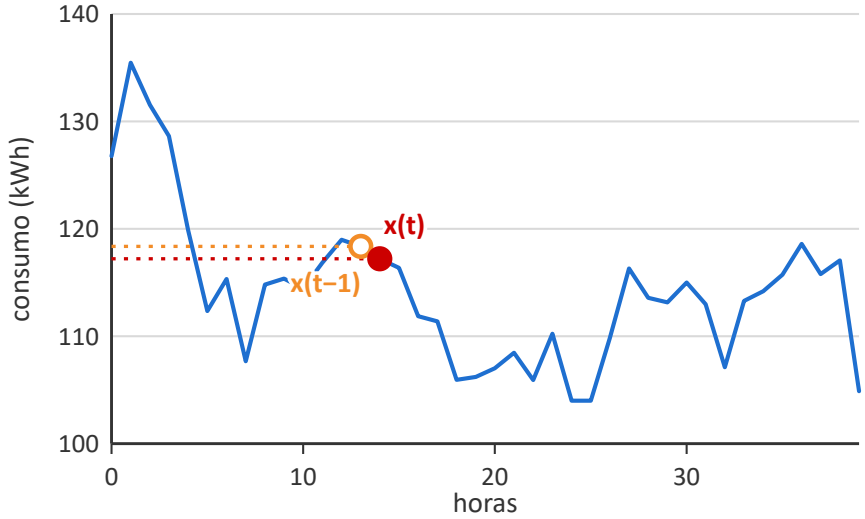
Defasagem e dispersão

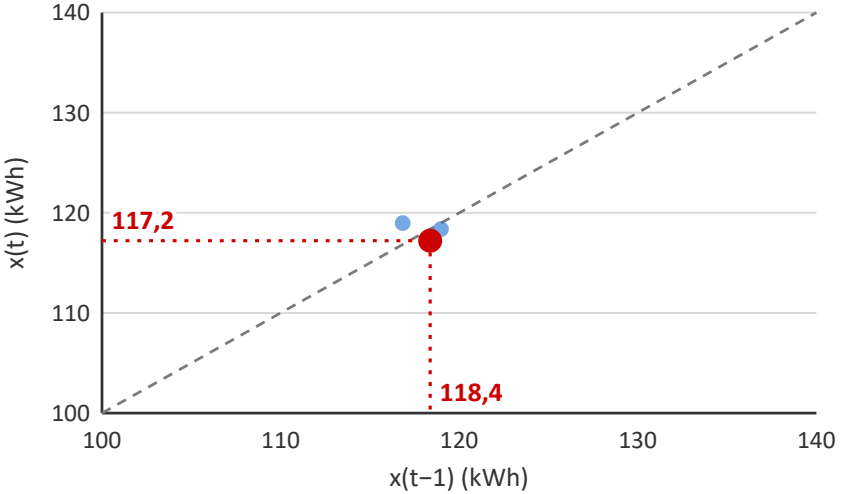




Uma hora depois, o par **avança 1 período**: novo par, novo ponto.

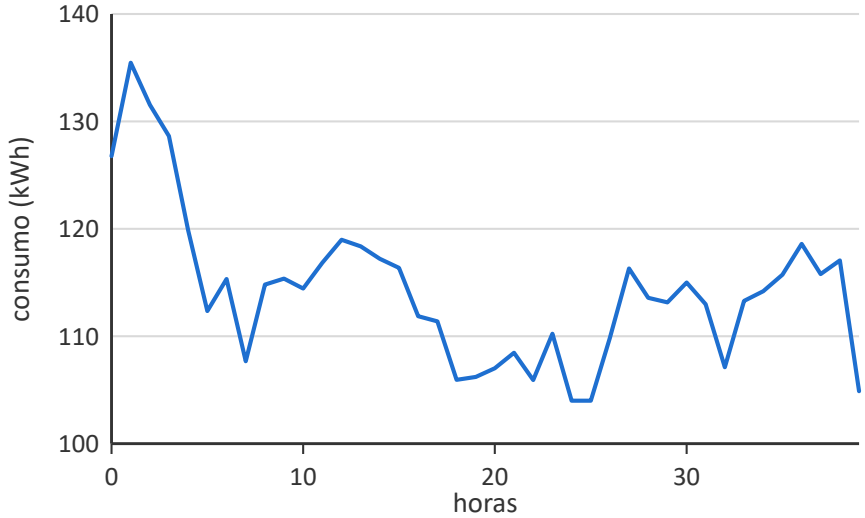
Defasagem e dispersão

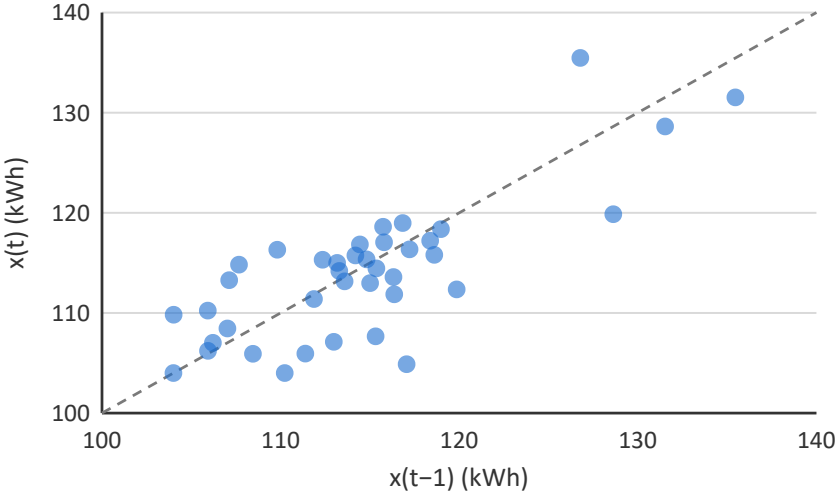




De novo, **um período por vez**.

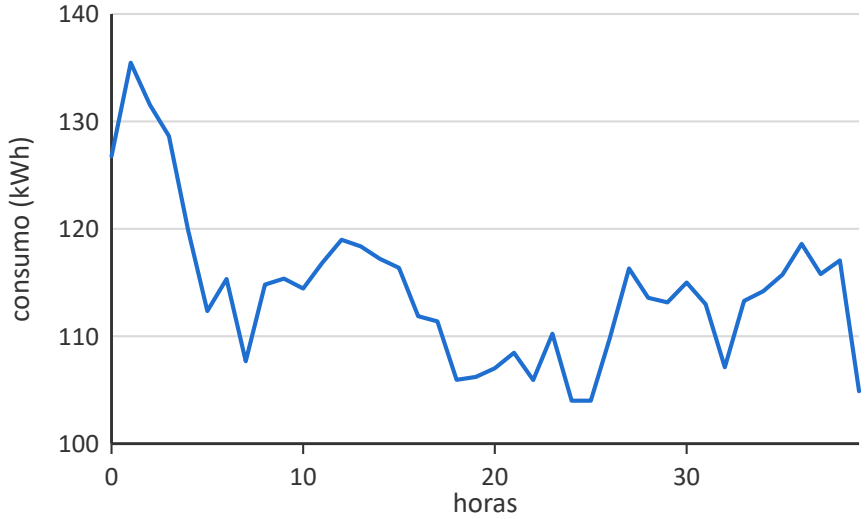
Defasagem e dispersão

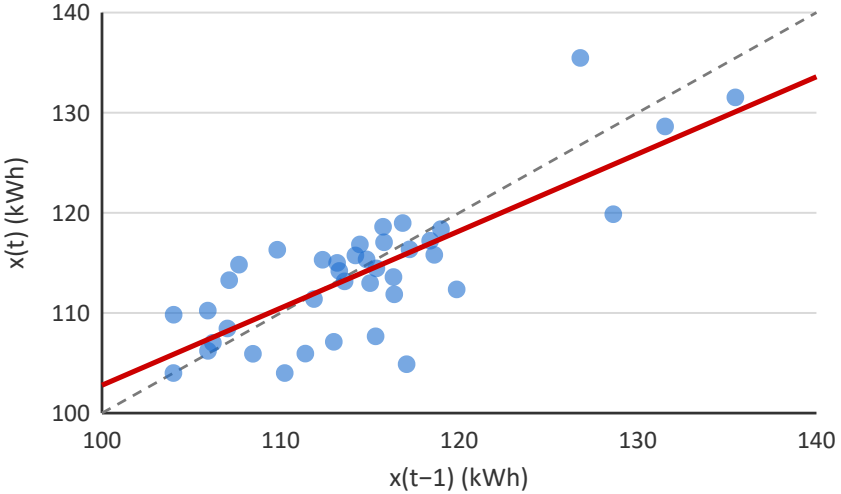




Todos os pares: a nuvem sobe na diagonal. **Valor alto vem depois de valor alto.**

Defasagem e dispersão



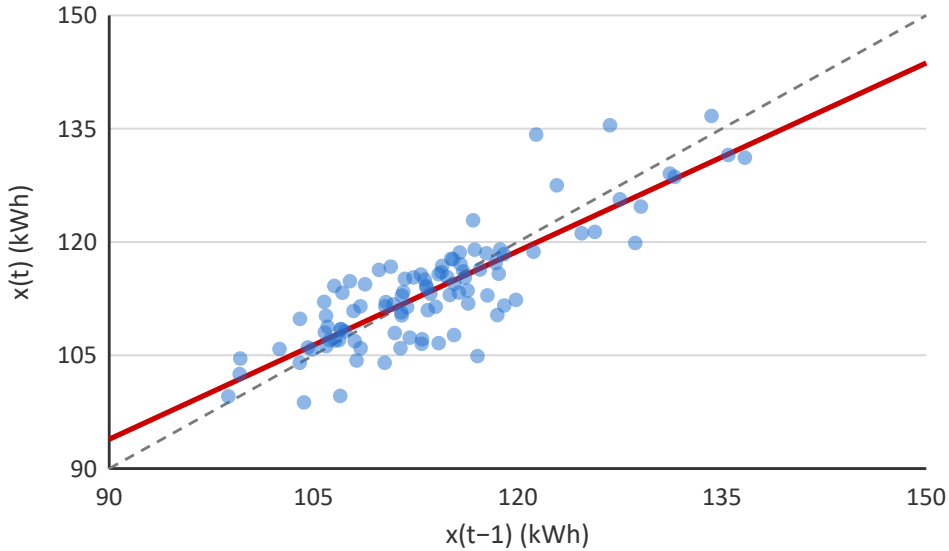


Uma **reta** resume a relação: é a regressão linear que vocês já conhecem.

Modelo AR

Modelo autorregressivo (AR)

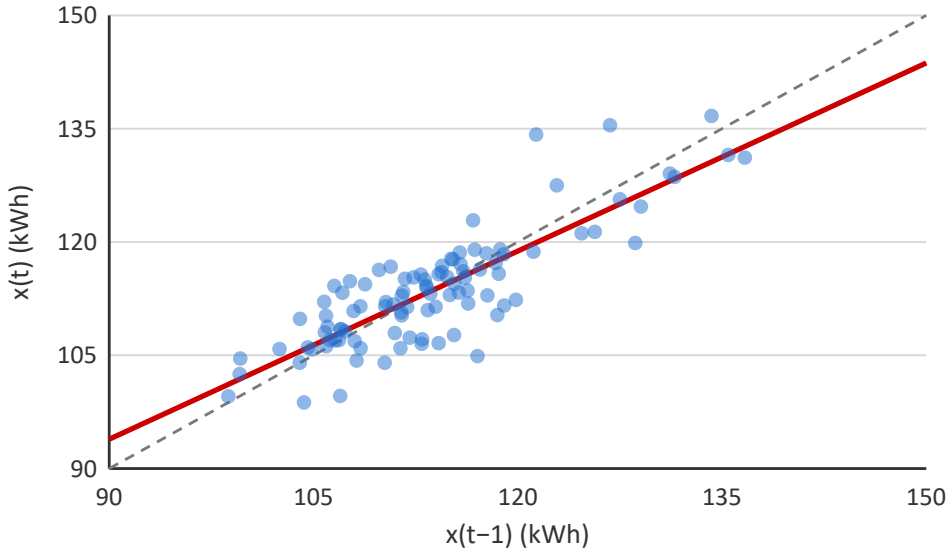
➡️ **AR(1)**: prever o valor de agora usando **só o valor anterior**, x_{t-1}



Modelo autorregressivo (AR)

➡️ **AR(1)**: prever o valor de agora usando **só o valor anterior**, x_{t-1}

➡️ A reta sobre a nuvem é a equação do modelo

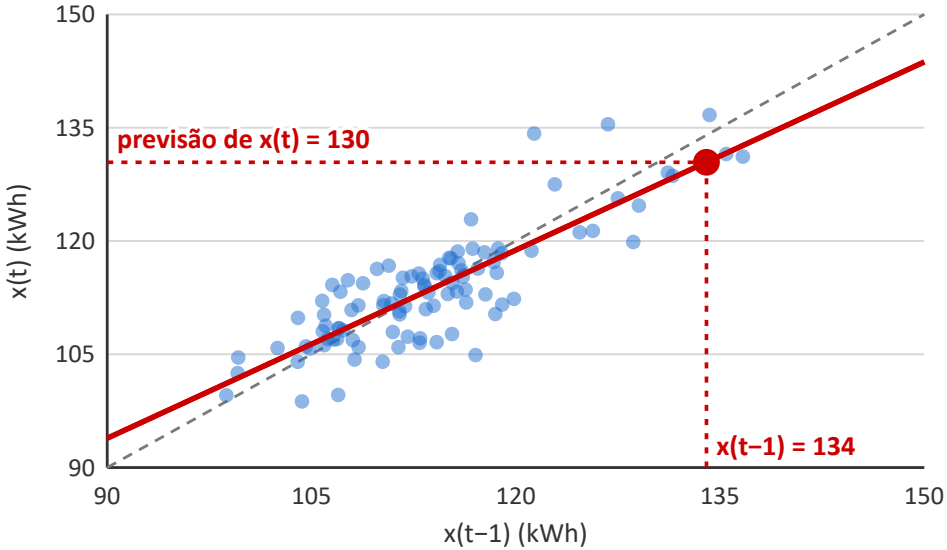


$$x_t = c + \varphi\, x_{t-1} + \varepsilon_t$$

c: constante (intercepto da reta) · φ: inclinação da reta, o peso do passado · ε_t: erro da regressão

Modelo autorregressivo (AR)

- **AR(1)**: prever o valor de agora usando **só o valor anterior**, x_{t-1}
- A reta sobre a nuvem é a equação do modelo
- Com x_{t-1} conhecido, a reta devolve a previsão de x_t

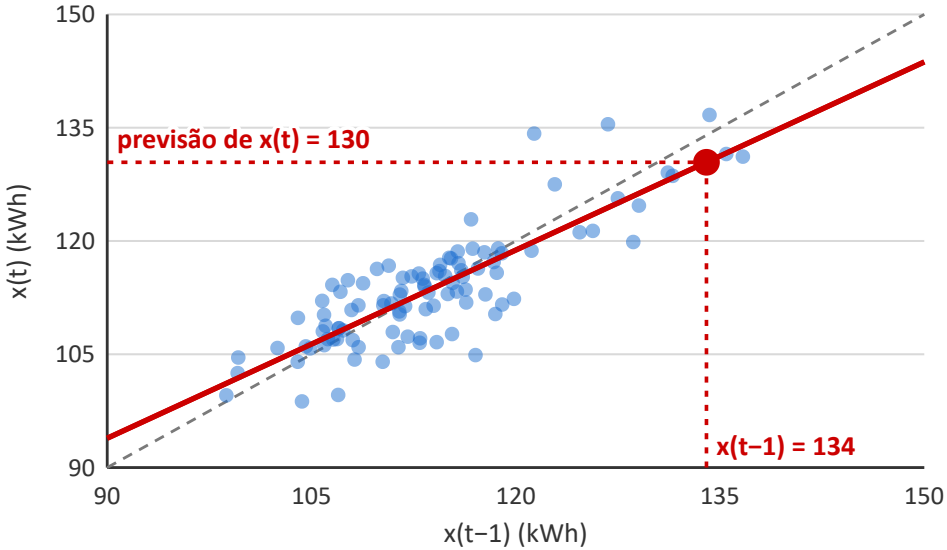


$$x_t = c + \varphi\, x_{t-1} + \varepsilon_t$$

c: constante (intercepto da reta) · φ: inclinação da reta, o peso do passado · ε_t: erro da regressão

Modelo autorregressivo (AR)

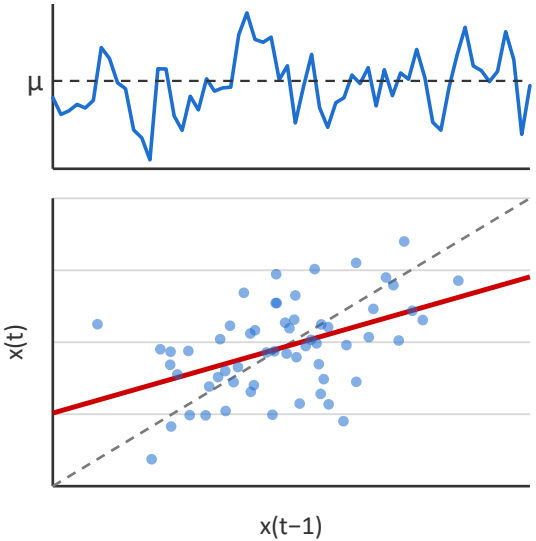
- **AR(1)**: prever o valor de agora usando **só o valor anterior**, x_{t-1}
- A reta sobre a nuvem é a equação do modelo
- Com x_{t-1} conhecido, a reta devolve a previsão de x_t
- Com mais valores anteriores: **AR(p)**



$$x_t = c + \varphi\, x_{t-1} + \varepsilon_t$$

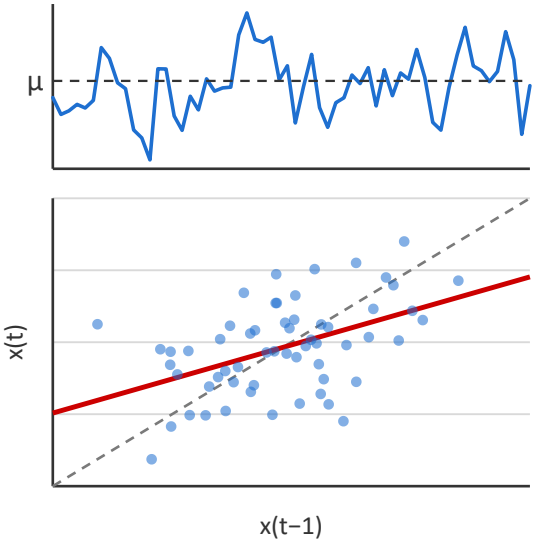
c: constante (intercepto da reta) · φ: inclinação da reta, o peso do passado · ε_t: erro da regressão

Parâmetro φ

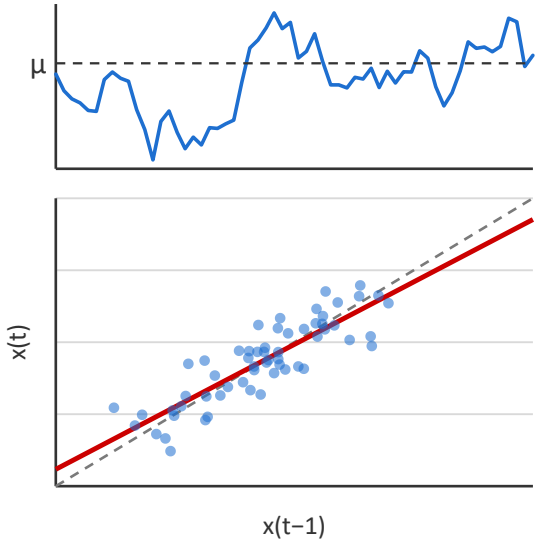


φ = 0,4: memória curta
cruza a média muitas vezes

Parâmetro φ

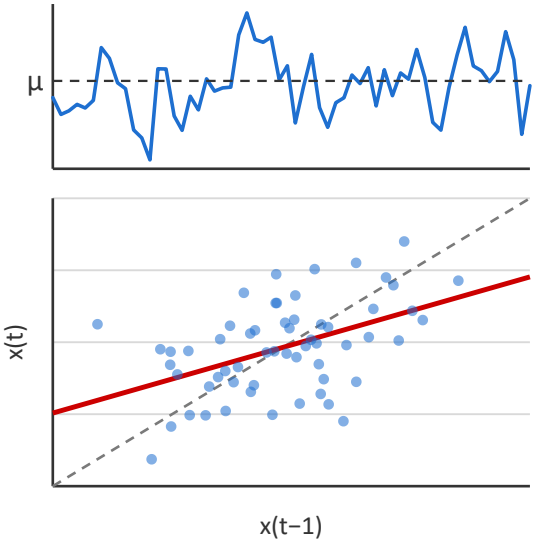


φ = 0,4: memória curta
cruza a média muitas vezes

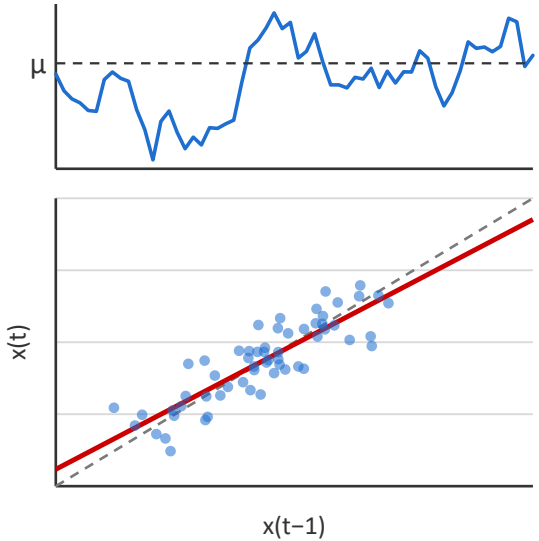


φ = 0,9: memória longa
demora a cruzar a média

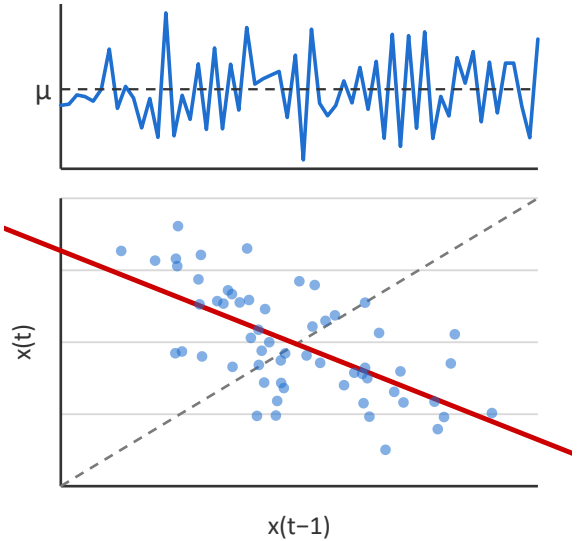
Parâmetro φ



φ = 0,4: memória curta
cruza a média muitas vezes

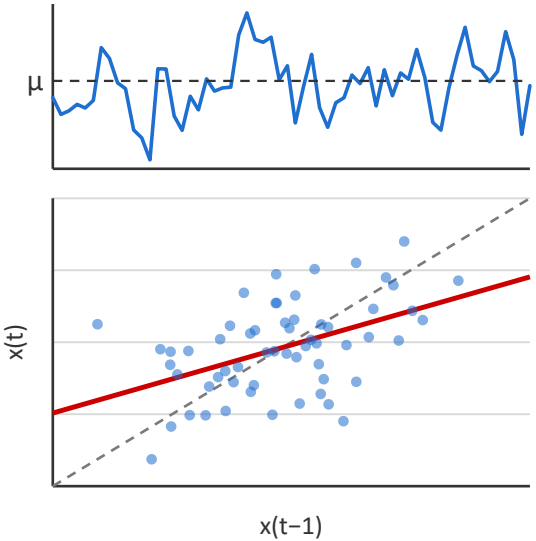


φ = 0,9: memória longa
demora a cruzar a média

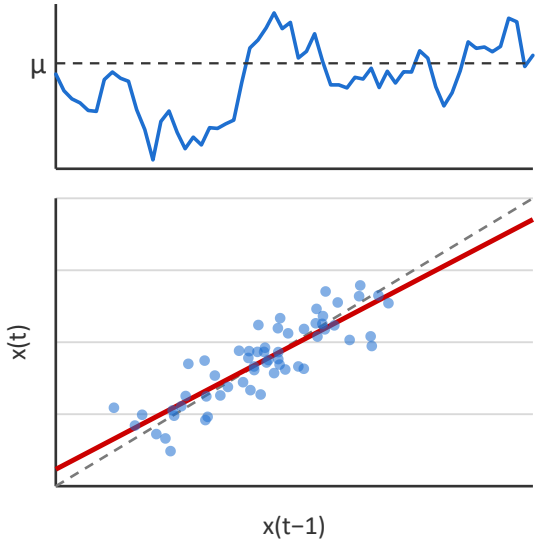


φ = −0,7: alterna de sinal
picos para cima e para baixo

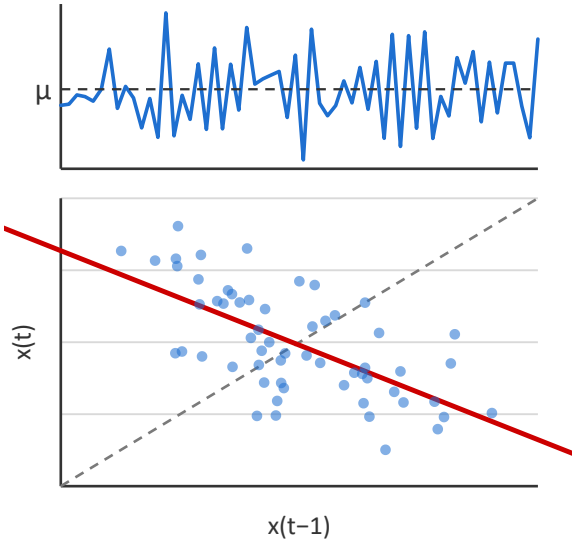
Parâmetro φ



$\varphi = 0{,}4$: memória curta
cruza a média muitas vezes



$\varphi = 0{,}9$: memória longa
demora a cruzar a média



$\varphi = -0{,}7$: alterna de sinal
picos para cima e para baixo

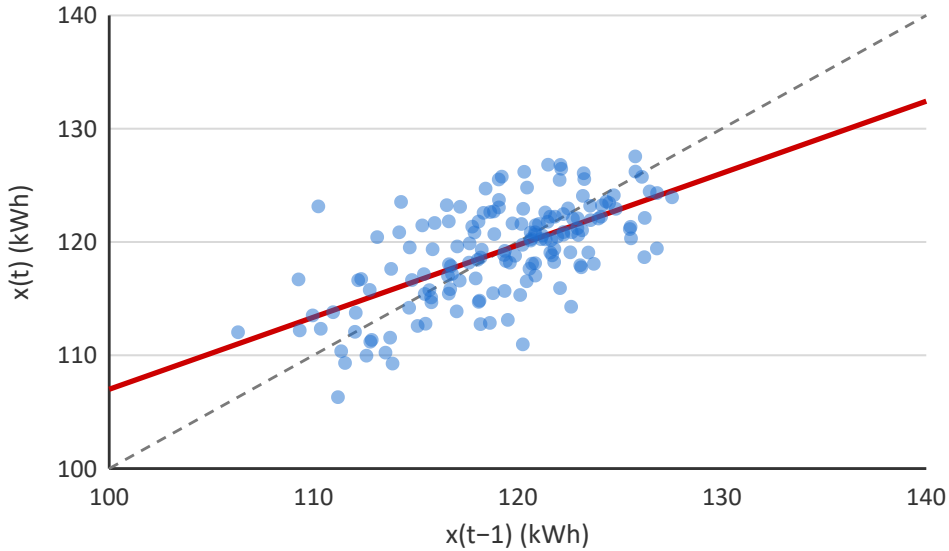
φ é a **inclinação** da reta: quanto maior $|\varphi|$, mais forte a dependência e mais alinhada a nuvem. O sinal dá a direção.

Ordem p

➡️ **AR(p)**: o valor depende dos p valores anteriores

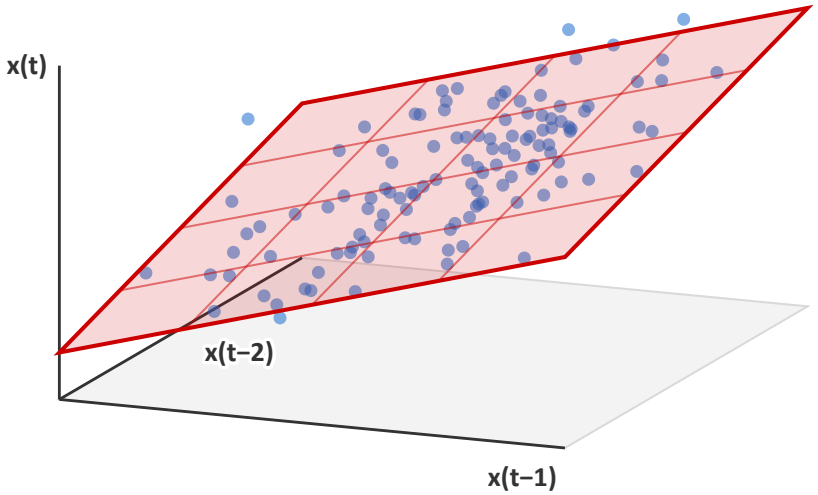
Ordem p

- **AR(p)**: o valor depende dos p valores anteriores
- $p = 1$: só o anterior, uma **reta**



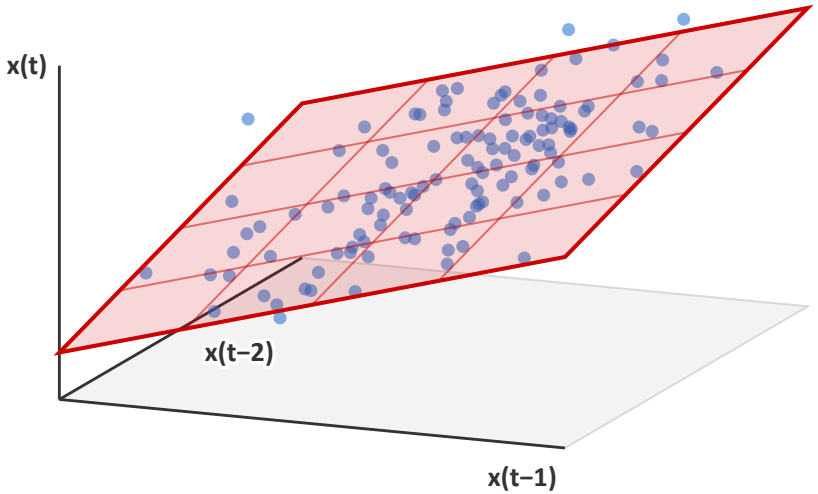
Ordem p

- **AR(p)**: o valor depende dos p valores anteriores
- $p = 1$: só o anterior, uma **reta**
- $p = 2$: os dois anteriores, um **plano**



Ordem p

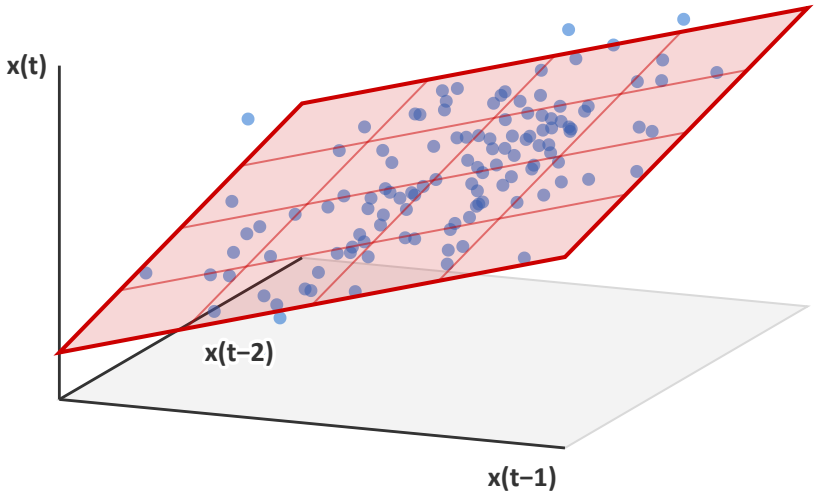
- **AR(p)**: o valor depende dos p valores anteriores
- p = 1: só o anterior, uma **reta**
- p = 2: os dois anteriores, um **plano**
- p qualquer: um valor previsto por p entradas



$$x_t = c + \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \ldots + \varphi_p x_{t-p} + \varepsilon_t$$

Ordem p

- **AR(p)**: o valor depende dos p valores anteriores
- p = 1: só o anterior, uma **reta**
- p = 2: os dois anteriores, um **plano**
- p qualquer: um valor previsto por p entradas



$$x_t = c + \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \ldots + \varphi_p x_{t-p} + \varepsilon_t$$

Mais lags: mais memória, mas também mais parâmetros para estimar.

Modelo MA

Modelo de médias móveis (MA)

Média móvel: uma média que se **movimenta** no tempo. Na Aula 2 usamos a média dos **valores observados**.

Média móvel (Aula 2)

$$MM_t = \frac{X_t + X_{t-1}}{2}$$

Média de 2 **valores observados**, com pesos iguais

Modelo de médias móveis (MA)

Média móvel: uma média que se **movimenta** no tempo. Na Aula 2 usamos a média dos **valores observados**.

Média móvel (Aula 2)

$$MM_t = \frac{X_t + X_{t-1}}{2}$$

Média de 2 **valores observados**, com pesos iguais

Modelo MA(1)

$$X_t = \mu + \varepsilon_t + \theta\,\varepsilon_{t-1}$$

Combina 2 **erros aleatórios**, com pesos que podem ser diferentes

μ: a média global da série

Modelo de médias móveis (MA)

Com três termos: a mesma ideia, uma janela maior.

Média móvel (Aula 2)

$$MM_t = \frac{X_t + X_{t-1} + X_{t-2}}{3}$$

Média de 3 **valores observados**, com pesos iguais

Modelo de médias móveis (MA)

Com três termos: a mesma ideia, uma janela maior.

Média móvel (Aula 2)

$$MM_t = \frac{X_t + X_{t-1} + X_{t-2}}{3}$$

Média de 3 **valores observados**, com pesos iguais

Modelo MA(2)

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

Combina 3 **erros aleatórios**, com pesos que podem ser diferentes

Modelo de médias móveis (MA)

Com três termos: a mesma ideia, uma janela maior.

Média móvel (Aula 2)

$$MM_t = \frac{X_t + X_{t-1} + X_{t-2}}{3}$$

Média de 3 **valores observados**, com pesos iguais

Modelo MA(2)

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

Combina 3 **erros aleatórios**, com pesos que podem ser diferentes

Parecido na forma, mas é **outro método**: o MA combina **erros**, e não valores observados.

Modelo MA(0): previsão pela média

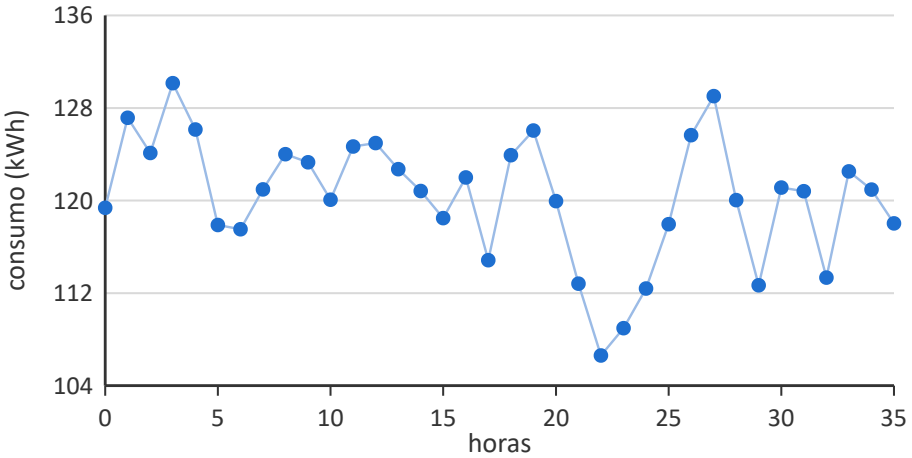
➡️ **MA(0)**: prever sempre pela **média** μ

$$x_t = \mu + \varepsilon_t$$

Modelo MA(0): previsão pela média

➡️ **MA(0)**: prever sempre pela **média** μ

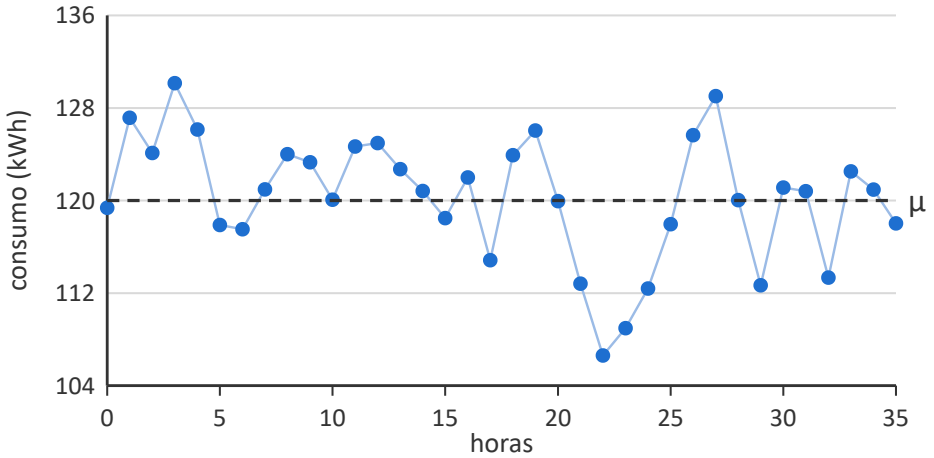
➡️ Pontos azuis: os **valores reais**



$$x_t = \mu + \varepsilon_t$$

Modelo MA(0): previsão pela média

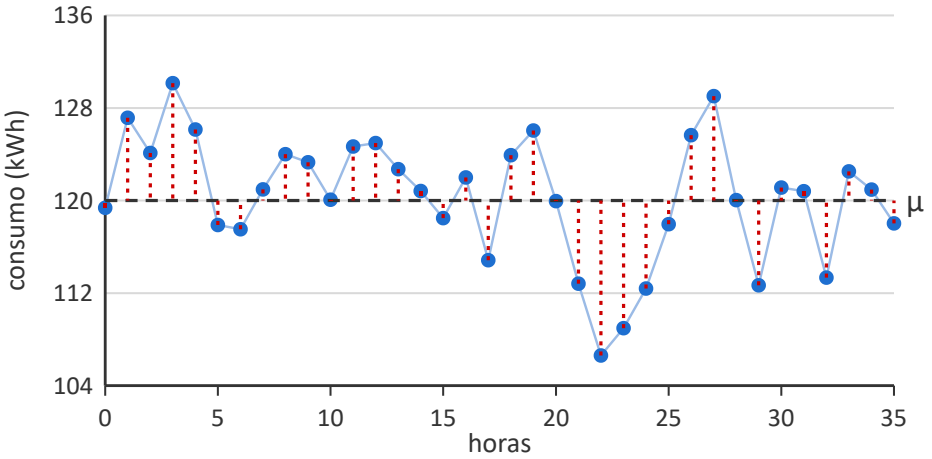
- **MA(0)**: prever sempre pela **média** μ
- Pontos azuis: os **valores reais**
- Linha tracejada: a média μ



$$x_t = \mu + \varepsilon_t$$

Modelo MA(0): previsão pela média

- **MA(0)**: prever sempre pela **média** μ
- Pontos azuis: os **valores reais**
- Linha tracejada: a média μ
- Verticais vermelhas: os **erros**, $\varepsilon_t = x_t - \mu$



$$x_t = \mu + \varepsilon_t$$

Modelo MA(1): previsão com o erro anterior

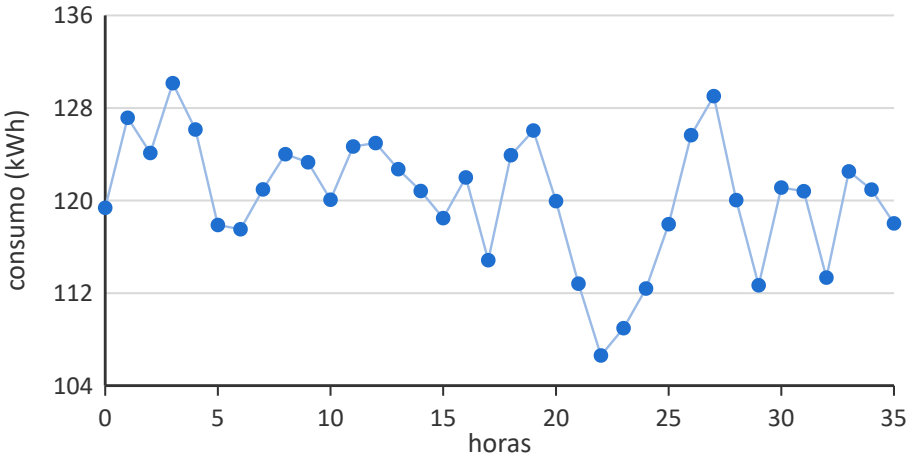
➡️ **MA(1)**: o erro do período anterior ajuda a explicar o desvio de agora

$$x_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

θ: peso do erro anterior · ε_{t-1}: erro de previsão do período anterior, calculado em sequência: $\varepsilon_t = x_t - \mu - \theta\,\varepsilon_{t-1}$

Modelo MA(1): previsão com o erro anterior

- **MA(1)**: o erro do período anterior ajuda a explicar o desvio de agora
- Pontos azuis: os **valores reais**

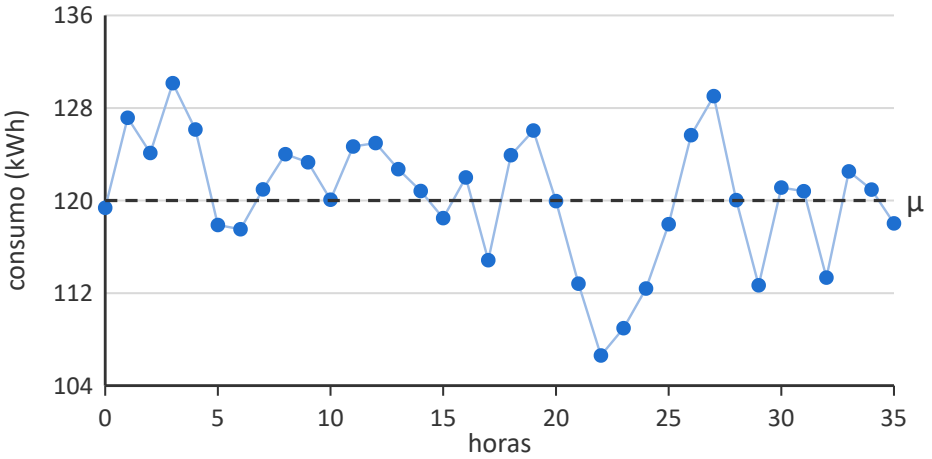


$$x_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

θ: peso do erro anterior · ε_{t-1}: erro de previsão do período anterior, calculado em sequência: $\varepsilon_t = x_t - \mu - \theta\,\varepsilon_{t-1}$

Modelo MA(1): previsão com o erro anterior

- ➡️ **MA(1)**: o erro do período anterior ajuda a explicar o desvio de agora
- ➡️ Pontos azuis: os **valores reais**
- ➡️ Linha tracejada: a média μ

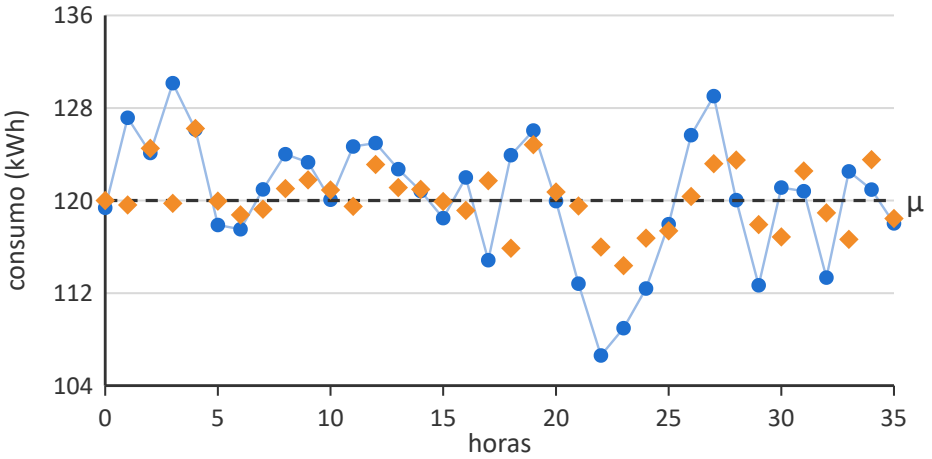


$$x_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

θ: peso do erro anterior · ε_{t-1}: erro de previsão do período anterior, calculado em sequência: $\varepsilon_t = x_t - \mu - \theta\,\varepsilon_{t-1}$

Modelo MA(1): previsão com o erro anterior

- **MA(1)**: o erro do período anterior ajuda a explicar o desvio de agora
- Pontos azuis: os **valores reais**
- Linha tracejada: a média μ
- Losangos laranja: a **previsão** de cada ponto, $\mu + \theta\,\varepsilon_{t-1}$

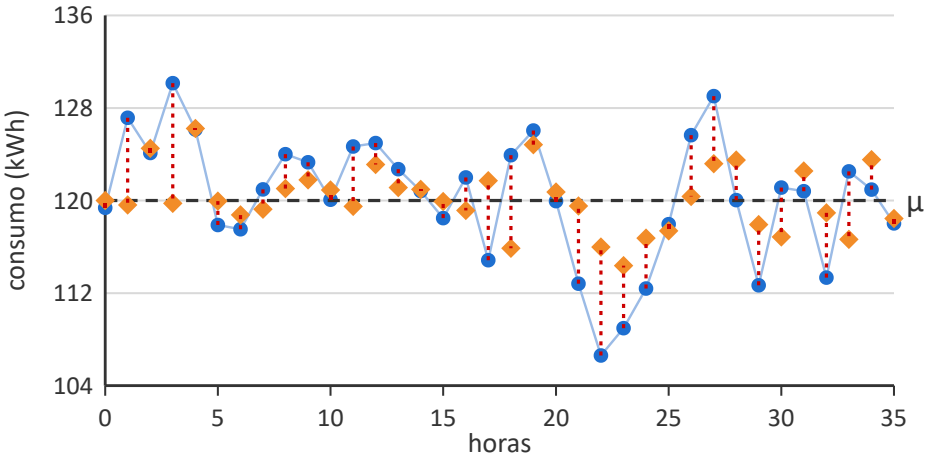


$$x_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

θ: peso do erro anterior · ε_{t-1}: erro de previsão do período anterior, calculado em sequência: $\varepsilon_t = x_t - \mu - \theta\,\varepsilon_{t-1}$

Modelo MA(1): previsão com o erro anterior

- **MA(1)**: o erro do período anterior ajuda a explicar o desvio de agora
- Pontos azuis: os **valores reais**
- Linha tracejada: a média μ
- Losangos laranja: a **previsão** de cada ponto, $\mu + \theta\,\varepsilon_{t-1}$
- Verticais vermelhas: os **erros** da previsão

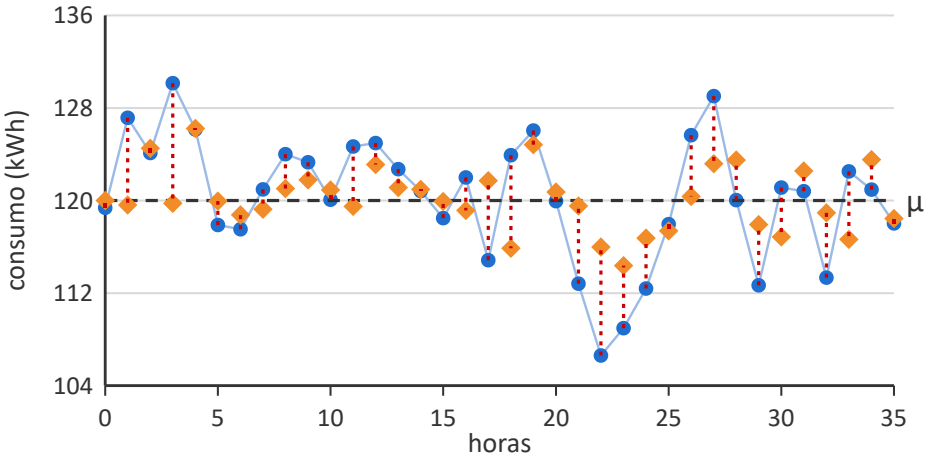


$$x_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

θ: peso do erro anterior · ε_{t-1}: erro de previsão do período anterior, calculado em sequência: $\varepsilon_t = x_t - \mu - \theta\,\varepsilon_{t-1}$

Modelo MA(1): previsão com o erro anterior

- **MA(1)**: o erro do período anterior ajuda a explicar o desvio de agora
- Pontos azuis: os **valores reais**
- Linha tracejada: a média μ
- Losangos laranja: a **previsão** de cada ponto, $\mu + \theta\,\varepsilon_{t-1}$
- Verticais vermelhas: os **erros** da previsão
- O erro de agora, ε_t, só é conhecido depois que o valor acontece



$$x_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

θ: peso do erro anterior · ε_{t-1}: erro de previsão do período anterior, calculado em sequência: $\varepsilon_t = x_t - \mu - \theta\,\varepsilon_{t-1}$

Ordem q

➡️ **MA(q)**: o valor depende do erro de agora e dos q erros anteriores

Ordem q

➡️ **MA(q)**: o valor depende do erro de agora e dos q erros anteriores

q = 1

$$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

Ordem q

➡️ **MA(q)**: o valor depende do erro de agora e dos q erros anteriores

$q = 1$ $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

$q = 2$ $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

Ordem q

➡️ **MA(q)**: o valor depende do erro de agora e dos q erros anteriores

q = 1 $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

q = 2 $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

q qualquer $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \ldots + \theta_q \varepsilon_{t-q}$$

Ordem q

➡️ **MA(q)**: o valor depende do erro de agora e dos q erros anteriores

q = 1 $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

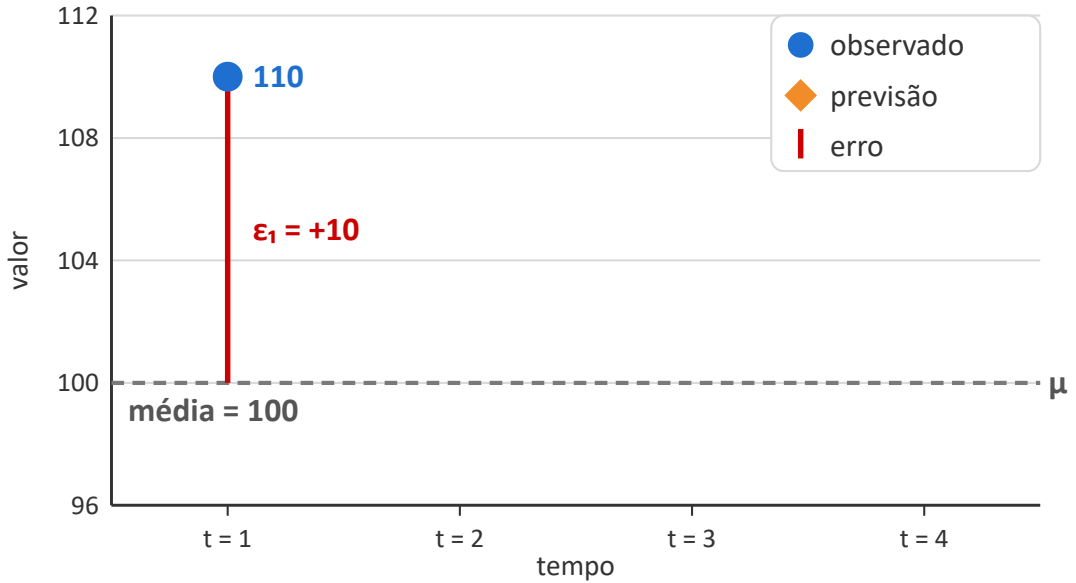
q = 2 $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

q qualquer $$x_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \ldots + \theta_q \varepsilon_{t-q}$$

> Mais erros: mais memória, mas também mais parâmetros para estimar. Depois de q períodos, o efeito de um erro **acaba**.

Exemplo: previsão com o MA(1)

$$\varepsilon_1 = 110 - 100 = 10$$

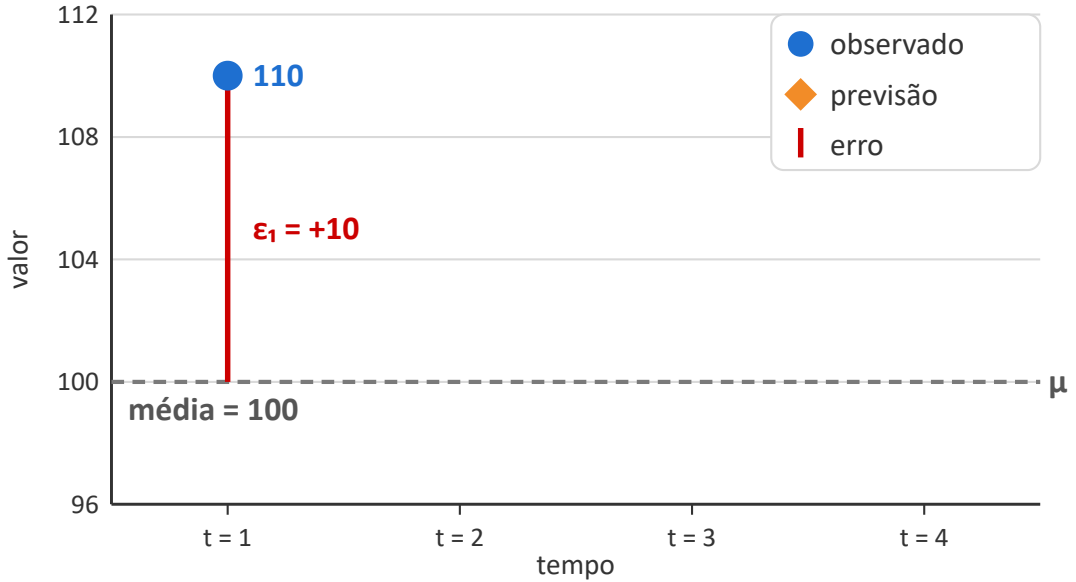


Exemplo: previsão com o MA(1)

$\varepsilon_1 = 110 - 100 = 10$

O erro anterior ajuda a prever o próximo valor?

$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1}$ com $\mu = 100$ e $\theta = 0{,}6$



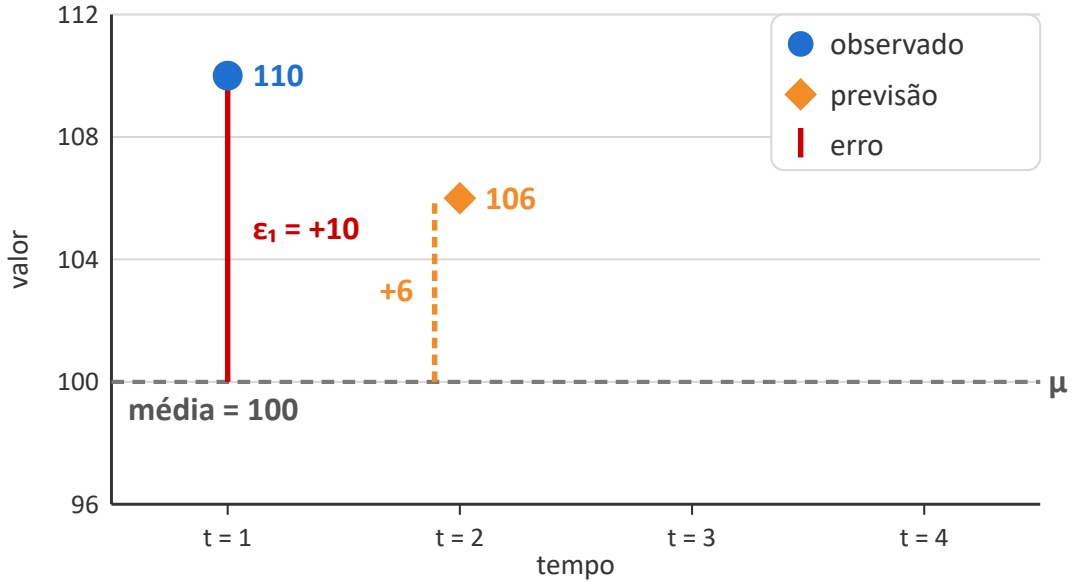
Exemplo: previsão com o MA(1)

$\varepsilon_1 = 110 - 100 = 10$

O erro anterior ajuda a prever o próximo valor?

$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1}$ com $\mu = 100$ e $\theta = 0{,}6$

$\hat{X}_2 = 100 + 0{,}6 \times 10 = 106$



Exemplo: previsão com o MA(1)

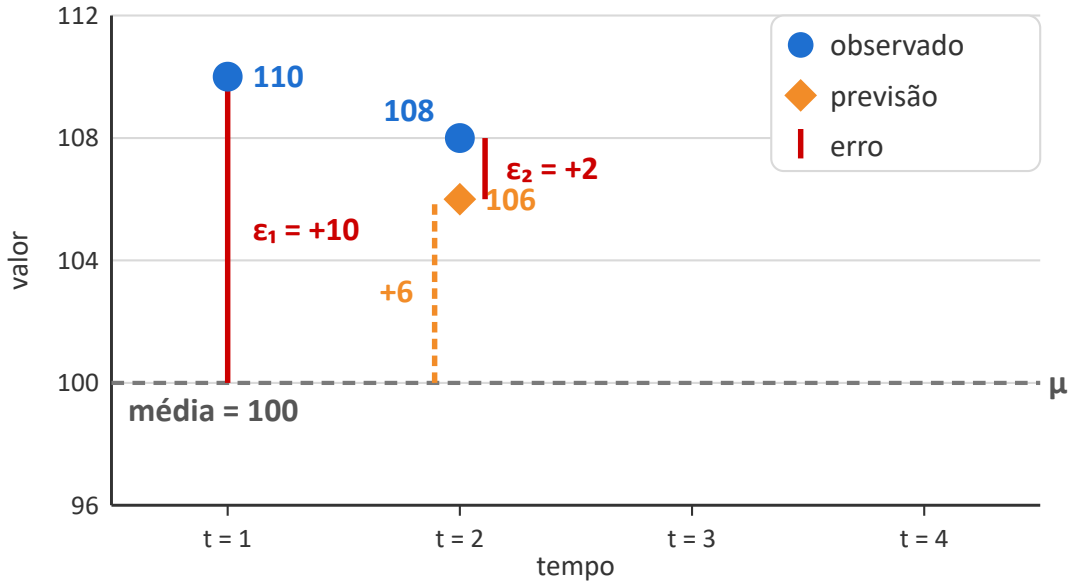
$$\varepsilon_1 = 110 - 100 = 10$$

O erro anterior ajuda a prever o próximo valor?

$$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1} \quad \text{com } \mu = 100 \text{ e } \theta = 0{,}6$$

$$\hat{X}_2 = 100 + 0{,}6 \times 10 = 106$$

$$\varepsilon_2 = 108 - 106 = 2$$



Exemplo: previsão com o MA(1)

$$\varepsilon_1 = 110 - 100 = 10$$

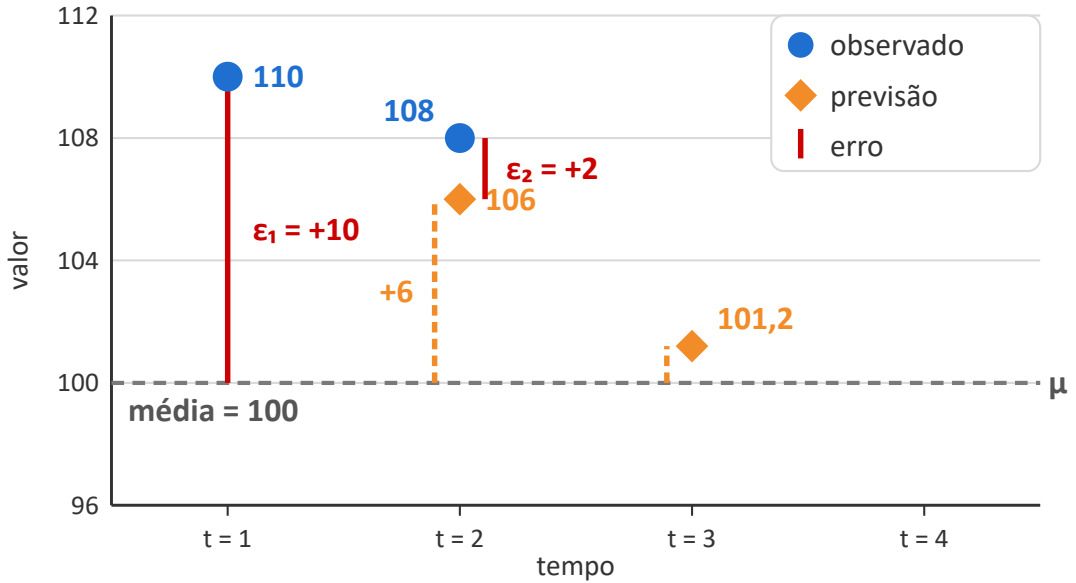
O erro anterior ajuda a prever o próximo valor?

$$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1} \quad \text{com } \mu = 100 \text{ e } \theta = 0{,}6$$

$$\hat{X}_2 = 100 + 0{,}6 \times 10 = 106$$

$$\varepsilon_2 = 108 - 106 = 2$$

$$\hat{X}_3 = 100 + 0{,}6 \times 2 = 101{,}2$$



Exemplo: previsão com o MA(1)

$$\varepsilon_1 = 110 - 100 = 10$$

O erro anterior ajuda a prever o próximo valor?

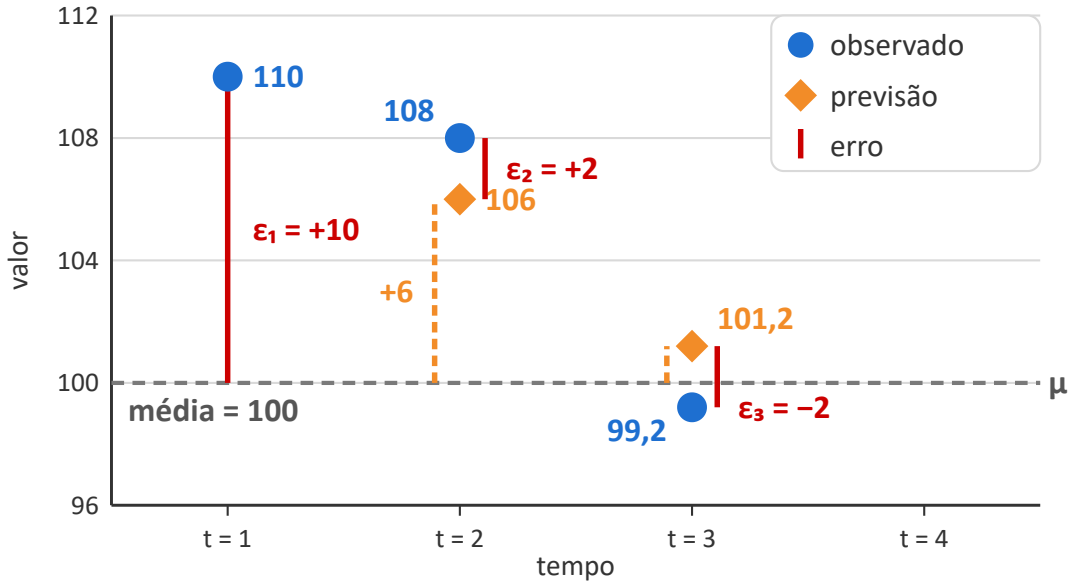
$$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1} \quad \text{com } \mu = 100 \text{ e } \theta = 0{,}6$$

$$\hat{X}_2 = 100 + 0{,}6 \times 10 = 106$$

$$\varepsilon_2 = 108 - 106 = 2$$

$$\hat{X}_3 = 100 + 0{,}6 \times 2 = 101{,}2$$

$$\varepsilon_3 = 99{,}2 - 101{,}2 = -2$$



Exemplo: previsão com o MA(1)

$$\varepsilon_1 = 110 - 100 = 10$$

O erro anterior ajuda a prever o próximo valor?

$$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1} \quad \text{com } \mu = 100 \text{ e } \theta = 0{,}6$$

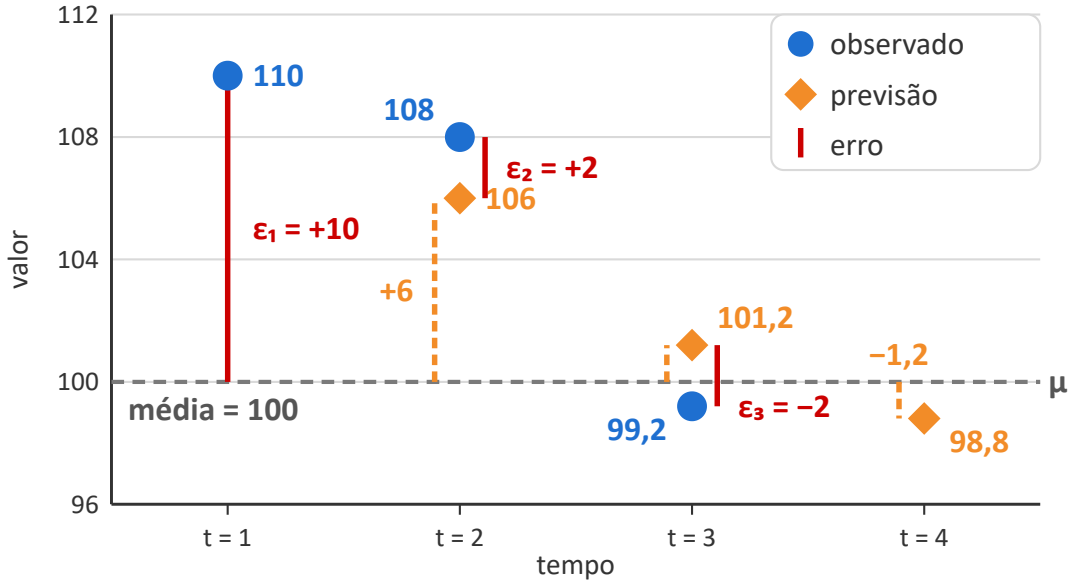
$$\hat{X}_2 = 100 + 0{,}6 \times 10 = 106$$

$$\varepsilon_2 = 108 - 106 = 2$$

$$\hat{X}_3 = 100 + 0{,}6 \times 2 = 101{,}2$$

$$\varepsilon_3 = 99{,}2 - 101{,}2 = -2$$

$$\hat{X}_4 = 100 + 0{,}6 \times (-2) = 98{,}8$$



Exemplo: previsão com o MA(1)

$\varepsilon_1 = 110 - 100 = 10$

O erro anterior ajuda a prever o próximo valor?

$\hat{X}_t = \mu + \theta\,\varepsilon_{t-1}$ com $\mu = 100$ e $\theta = 0{,}6$

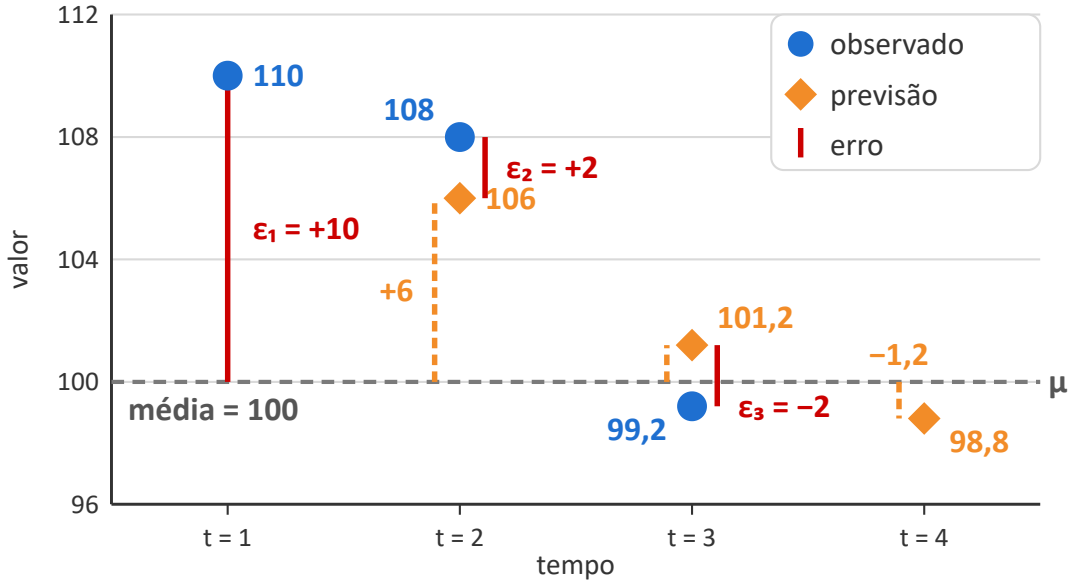
$\hat{X}_2 = 100 + 0{,}6 \times 10 = 106$

$\varepsilon_2 = 108 - 106 = 2$

$\hat{X}_3 = 100 + 0{,}6 \times 2 = 101{,}2$

$\varepsilon_3 = 99{,}2 - 101{,}2 = -2$

$\hat{X}_4 = 100 + 0{,}6 \times (-2) = 98{,}8$



$$X_t = \mu + \theta\,\varepsilon_{t-1} + \varepsilon_t$$

ε_t: a parcela que não conseguimos prever antecipadamente

Modelo ARMA

Modelo autorregressivo e de médias móveis (ARMA)

ARMA combina os dois modelos: a parte **AR** (valores passados) e a parte **MA** (erros passados)

$$X_t = c + \varphi X_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

parte AR · **parte MA** · **erro**

Modelo autorregressivo e de médias móveis (ARMA)

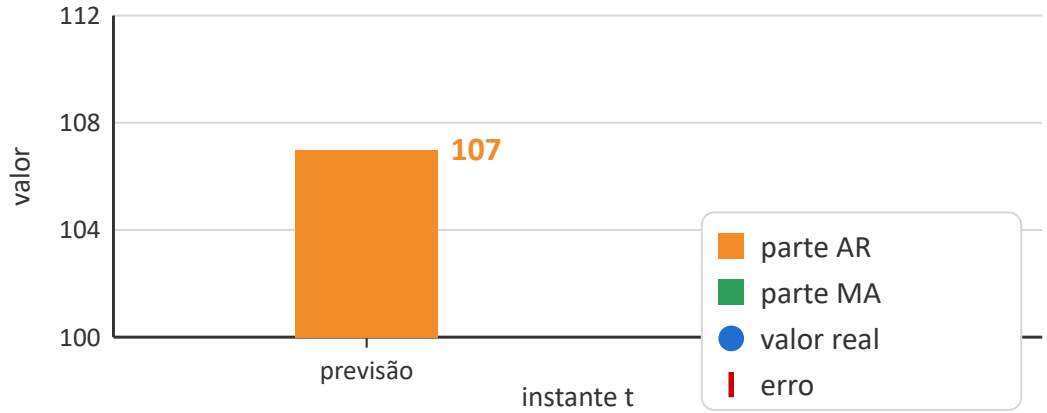
ARMA combina os dois modelos: a parte **AR** (valores passados) e a parte **MA** (erros passados)

$$X_t = c + \varphi X_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

parte AR · parte MA · erro

$c = 30$, $\varphi = 0{,}7$, $\theta = 0{,}5$; $X_{t-1} = 110$ e $\varepsilon_{t-1} = 4$

Parte AR: $30 + 0{,}7 \times 110 = 107$



Modelo autorregressivo e de médias móveis (ARMA)

ARMA combina os dois modelos: a parte **AR** (valores passados) e a parte **MA** (erros passados)

$$X_t = c + \varphi X_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

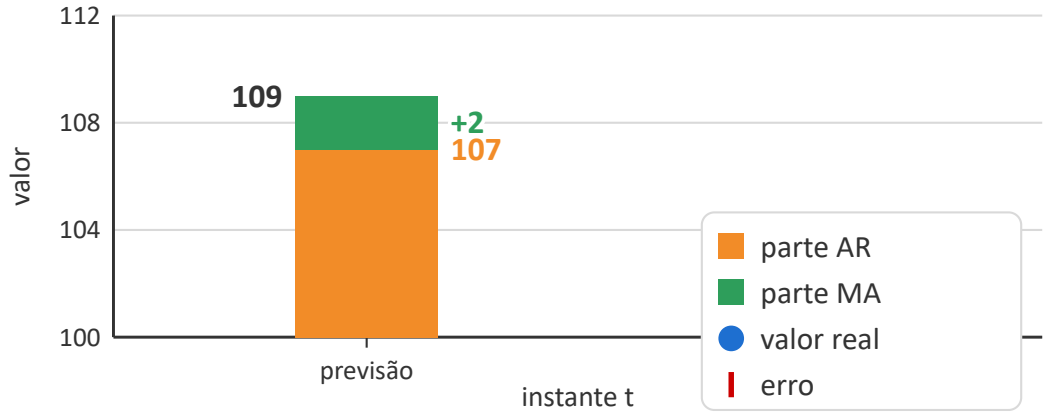
parte AR · parte MA · erro

$c = 30$, $\varphi = 0{,}7$, $\theta = 0{,}5$; $X_{t-1} = 110$ e $\varepsilon_{t-1} = 4$

Parte AR: $30 + 0{,}7 \times 110 = 107$

Parte MA: $0{,}5 \times 4 = 2$

Previsão: $107 + 2 = 109$



Modelo autorregressivo e de médias móveis (ARMA)

ARMA combina os dois modelos: a parte **AR** (valores passados) e a parte **MA** (erros passados)

$$X_t = c + \varphi X_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

parte AR · parte MA · erro

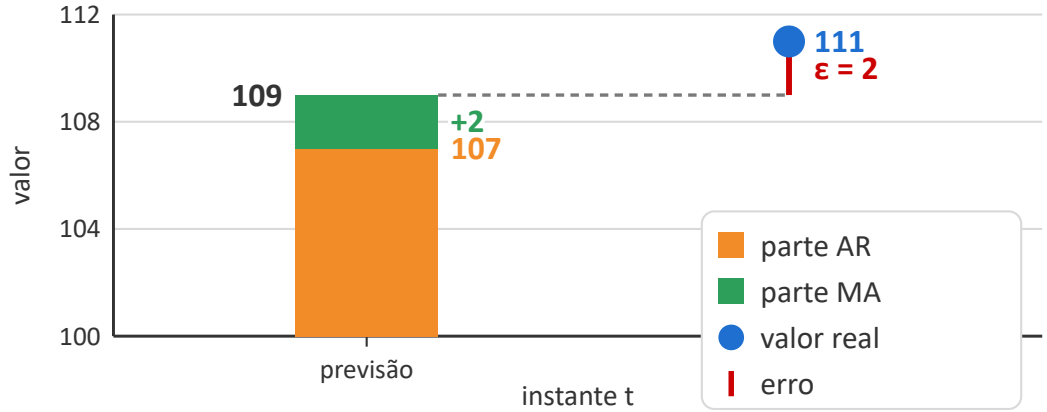
$c = 30$, $\varphi = 0{,}7$, $\theta = 0{,}5$; $X_{t-1} = 110$ e $\varepsilon_{t-1} = 4$

Parte AR: $30 + 0{,}7 \times 110 = 107$

Parte MA: $0{,}5 \times 4 = 2$

Previsão: $107 + 2 = 109$

$\varepsilon_t = 111 - 109 = 2$



Modelo autorregressivo e de médias móveis (ARMA)

ARMA combina os dois modelos: a parte **AR** (valores passados) e a parte **MA** (erros passados)

$$X_t = c + \varphi X_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

parte AR · parte MA · erro

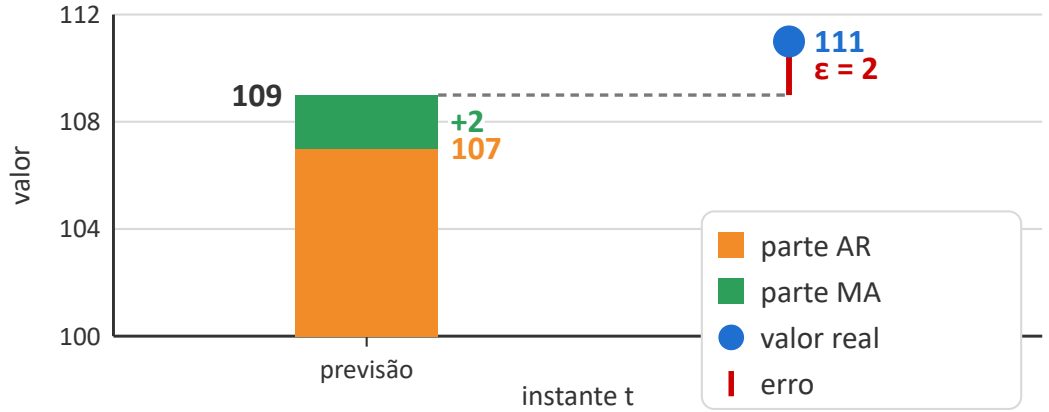
$c = 30$, $\varphi = 0{,}7$, $\theta = 0{,}5$; $X_{t-1} = 110$ e $\varepsilon_{t-1} = 4$

Parte AR: $30 + 0{,}7 \times 110 = 107$

Parte MA: $0{,}5 \times 4 = 2$

Previsão: $107 + 2 = 109$

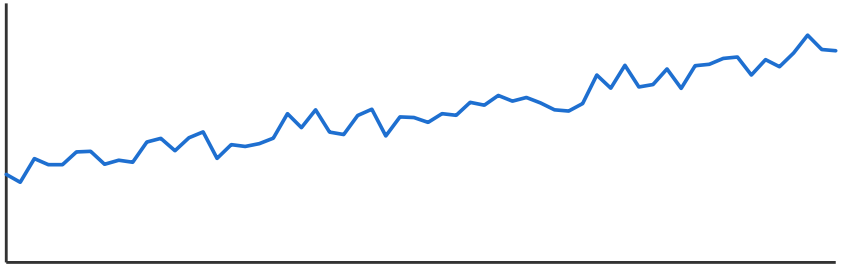
$\varepsilon_t = 111 - 109 = 2$



O **mesmo erro** aparece nas duas partes: é o erro do próprio ARMA. No próximo instante, ε_t vira ε_{t-1}.

Estacionariedade

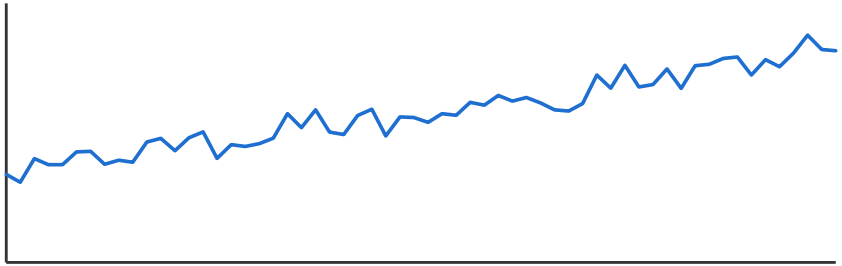
Série **estacionária**: média e variância constantes; a dependência entre dois pontos só depende da **distância** entre eles.



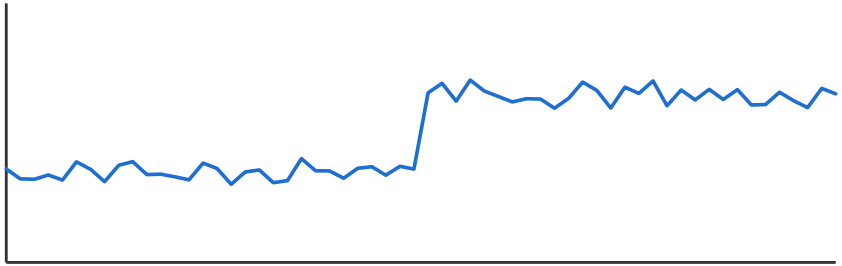
Média crescente (tendência)

Estacionariedade

Série **estacionária**: média e variância constantes; a dependência entre dois pontos só depende da **distância** entre eles.



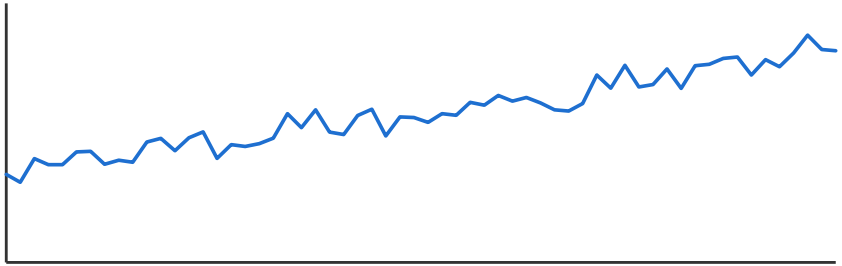
Média crescente (tendência)



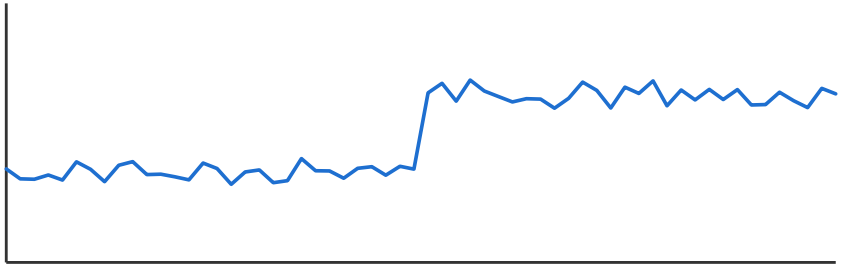
Média que muda de nível

Estacionariedade

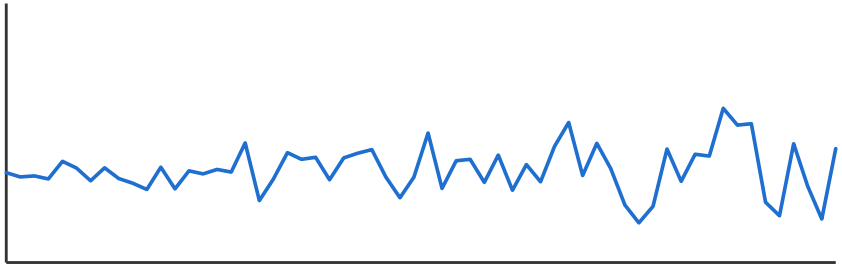
Série **estacionária**: média e variância constantes; a dependência entre dois pontos só depende da **distância** entre eles.



Média crescente (tendência)



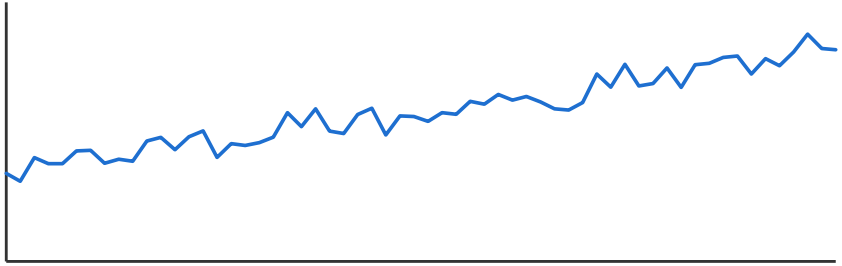
Média que muda de nível



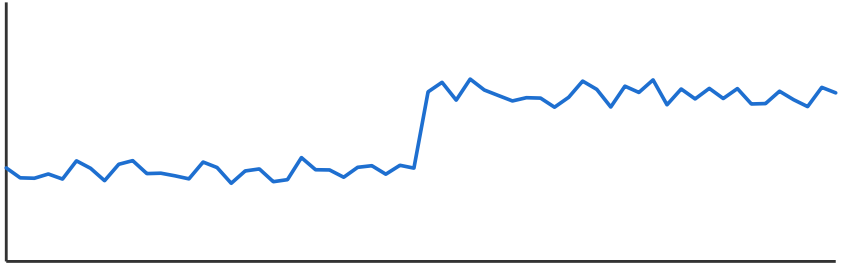
Variância crescente

Estacionariedade

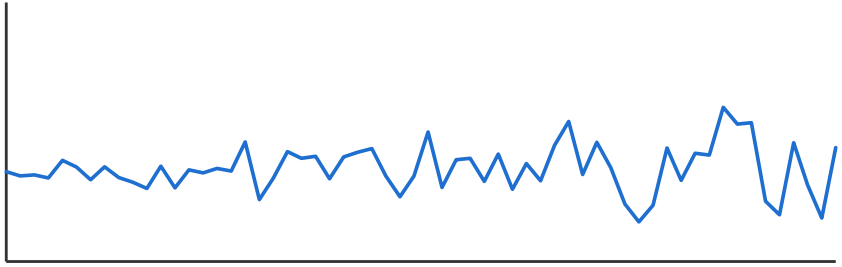
Série **estacionária**: média e variância constantes; a dependência entre dois pontos só depende da **distância** entre eles.



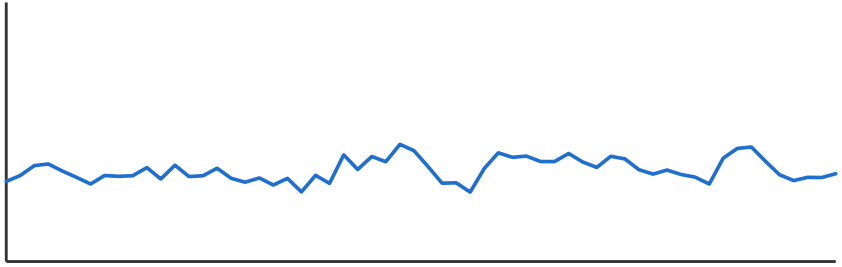
Média crescente (tendência)



Média que muda de nível



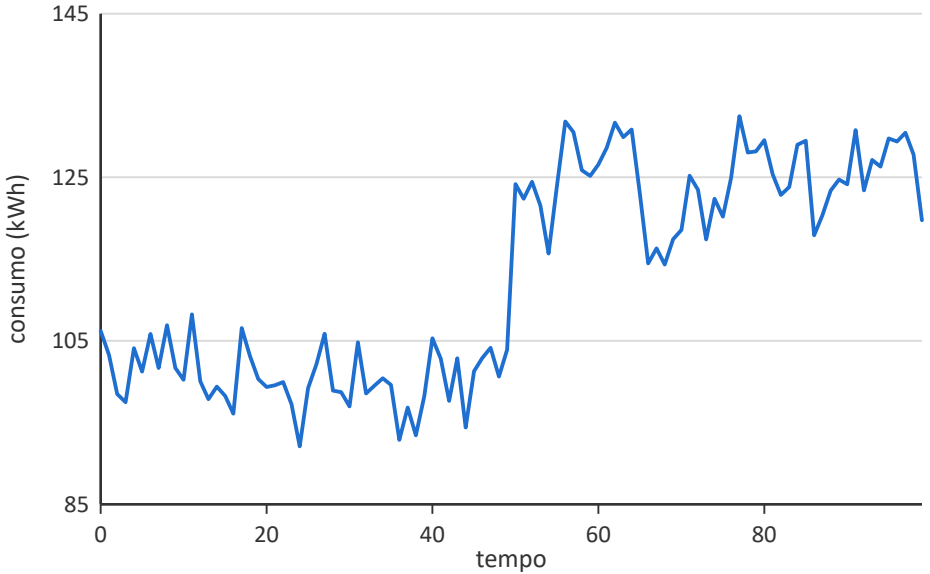
Variância crescente



Estacionária

Estacionariedade e previsão

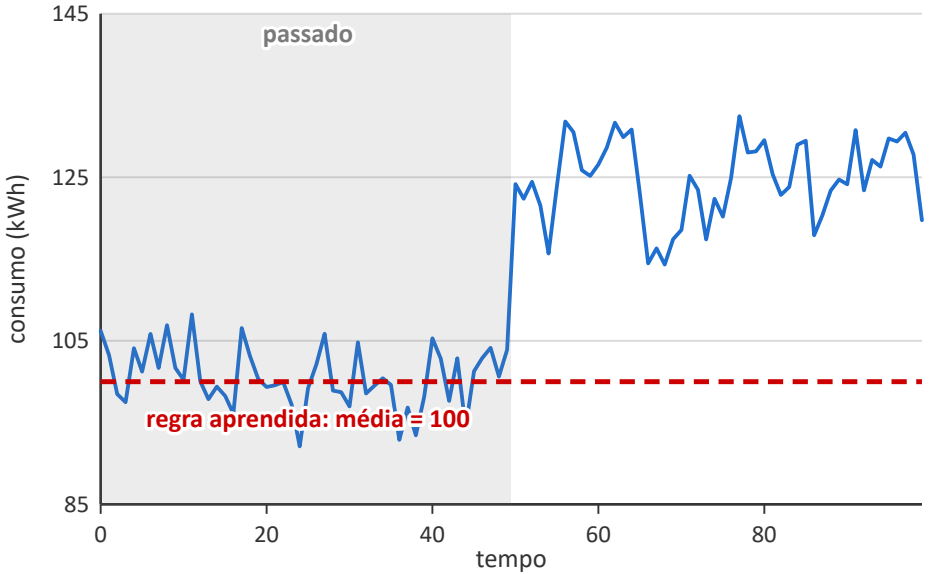
➡️ AR e MA aprendem uma **regra** do passado e a aplicam ao futuro



Estacionariedade e previsão

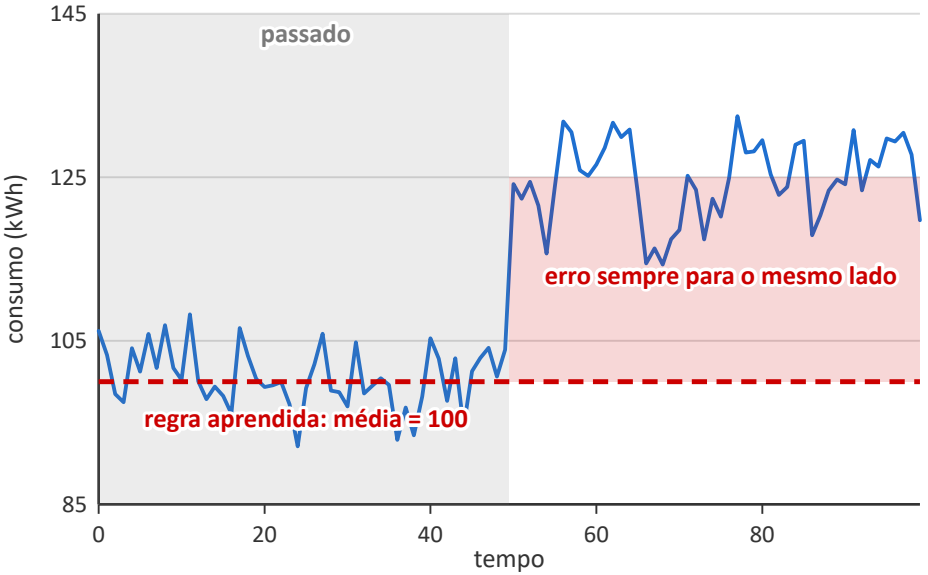
➡️ AR e MA aprendem uma **regra** do passado e a aplicam ao futuro

➡️ Se a série muda de comportamento, a regra **deixa de valer**



Estacionariedade e previsão

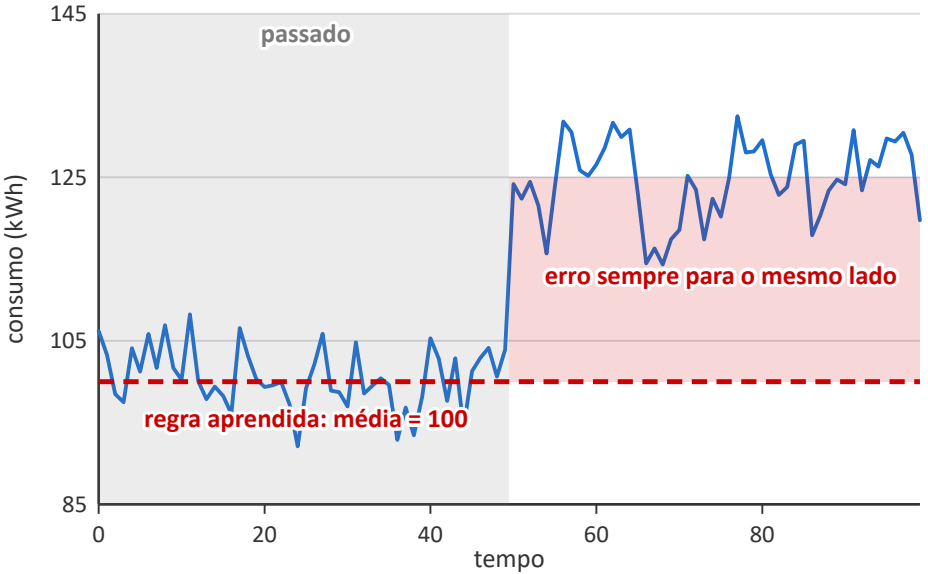
- AR e MA aprendem uma **regra** do passado e a aplicam ao futuro
- Se a série muda de comportamento, a regra **deixa de valer**
- Ex.: uma nova linha eleva o consumo, e a previsão erra **sempre para o mesmo lado**



Estacionariedade e previsão

- AR e MA aprendem uma **regra** do passado e a aplicam ao futuro
- Se a série muda de comportamento, a regra **deixa de valer**
- Ex.: uma nova linha eleva o consumo, e a previsão erra **sempre para o mesmo lado**

> Série não estacionária: **transformar antes** de modelar (Aula 4).



Resumo

➡️ **AR**: o valor de agora depende do passado da série, como uma regressão sobre valores defasados

Resumo

➡️ **AR**: o valor de agora depende do passado da série, como uma regressão sobre valores defasados

➡️ **MA**: depende dos erros passados. **ARMA**: os dois

Resumo

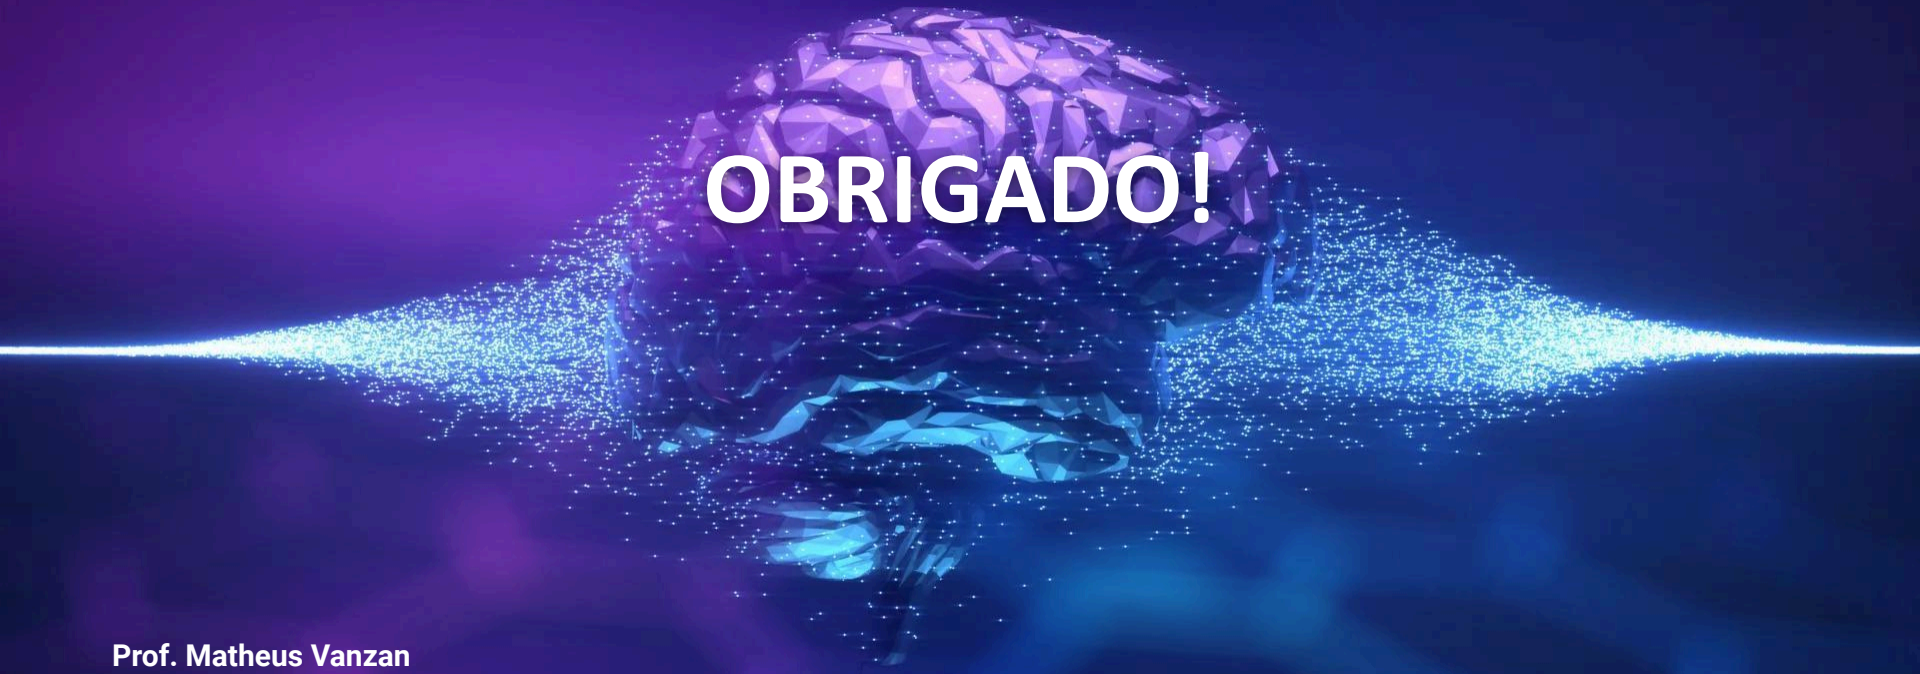
➡️ **AR**: o valor de agora depende do passado da série, como uma regressão sobre valores defasados

➡️ **MA**: depende dos erros passados. **ARMA**: os dois

➡️ A **estacionariedade** é a condição para a regra do passado continuar valendo


MOMENTO DE
PRÁTICA

RESIDÊNCIA
INTELIGÊNCIA ARTIFICIAL



OBRIGADO!

Prof. Matheus Vanzan
matheusvanzan.prof@gmail.com

FIESC UniSENAI INSTITUTO SENAI DE TECNOLOGIA INSTITUTO SENAI DE INOVAÇÃO