
RESIDÊNCIA
INTELIGÊNCIA ARTIFICIAL
FIESC
UniSENAI
INSTITUTO SENAI DE TECNOLOGIA
INSTITUTO SENAI DE INOVAÇÃO

RESIDÊNCIA INTELIGÊNCIA ARTIFICIAL

FIESC UniSENAI INSTITUTO SENAI DE TECNOLOGIA INSTITUTO SENAI DE INOVAÇÃO

Aula 4
Modelos ARIMA

Prof. Matheus Vanzan

Séries Temporais

Revisão: AR, MA e ARMA

AR (autorregressivo)

O valor de hoje depende dos **valores passados** da série

$$x_t = c + \varphi\, x_{t-1} + \varepsilon_t$$

ϕ pesa o valor anterior

MA (médias móveis)

O valor de hoje depende dos **erros passados** do modelo

$$x_t = \mu + \varepsilon_t + \theta\, \varepsilon_{t-1}$$

θ pesa o erro anterior; μ é a média

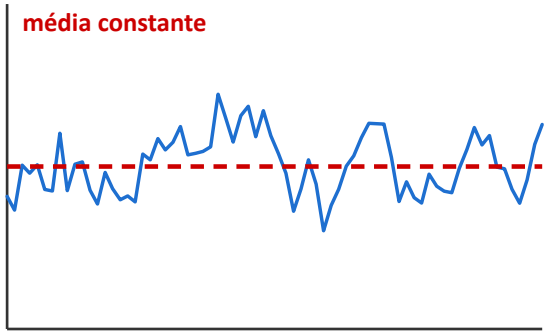
ARMA: os dois juntos, a parte AR e a parte MA

$$x_t = c + \varphi\, x_{t-1} + \theta\, \varepsilon_{t-1} + \varepsilon_t$$

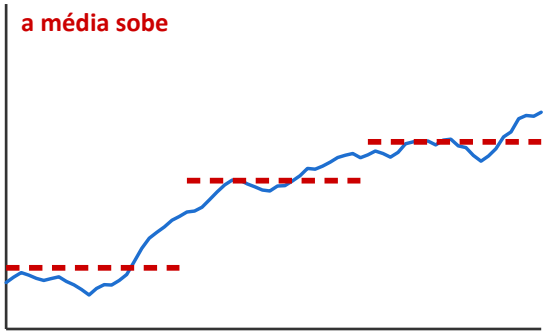
Objetivos da aula

- **Diferenciar** séries não estacionárias e voltar à escala original
- Entender o modelo **ARIMA(p,d,q)**, autorregressivo integrado de médias móveis, e o papel de cada parâmetro
- Escolher a ordem pela **validação** (MAE e RMSE) ou pelo **AIC e BIC**, e avaliar no **teste**
- Diagnosticar os **resíduos** do modelo

Quando AR e MA funcionam?



Estacionária



Não estacionária: a média muda

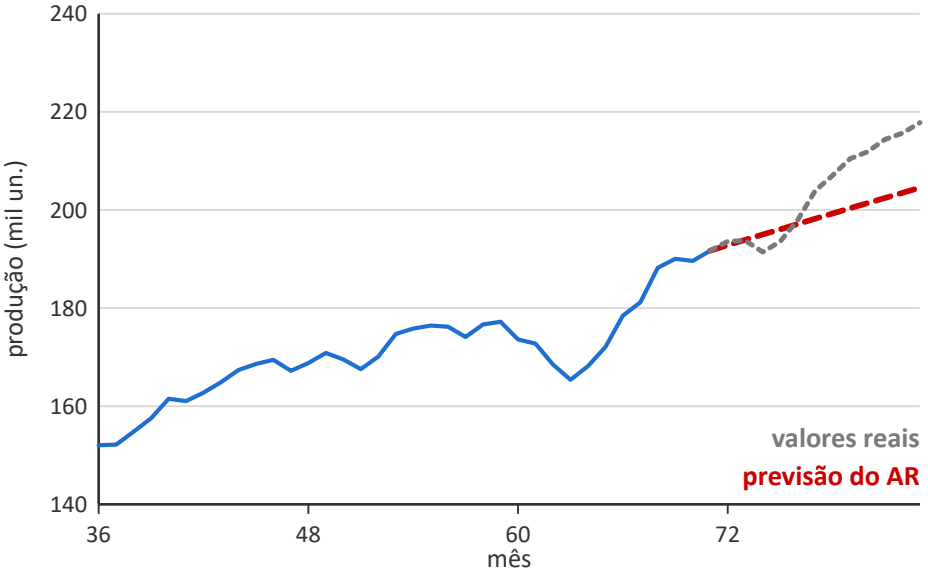


Não estacionária: a variância muda

AR e MA pressupõem séries **estacionárias**: média e variância constantes. Quando a média ou a variância muda, a previsão tende a errar.

Por que diferenciar?

- ➡️ Uma série com **tendência** tem a média subindo com o tempo
- ➡️ Um AR ajustado direto na série pode **não acompanhar** o crescimento
- ➡️ No exemplo, o **erro cresce** a cada mês
- ➡️ Solução: **diferenciar** para remover a tendência



Diferenciação

➡️ **Diferenciação**: cada ponto da série continua, agora em forma de **variação**

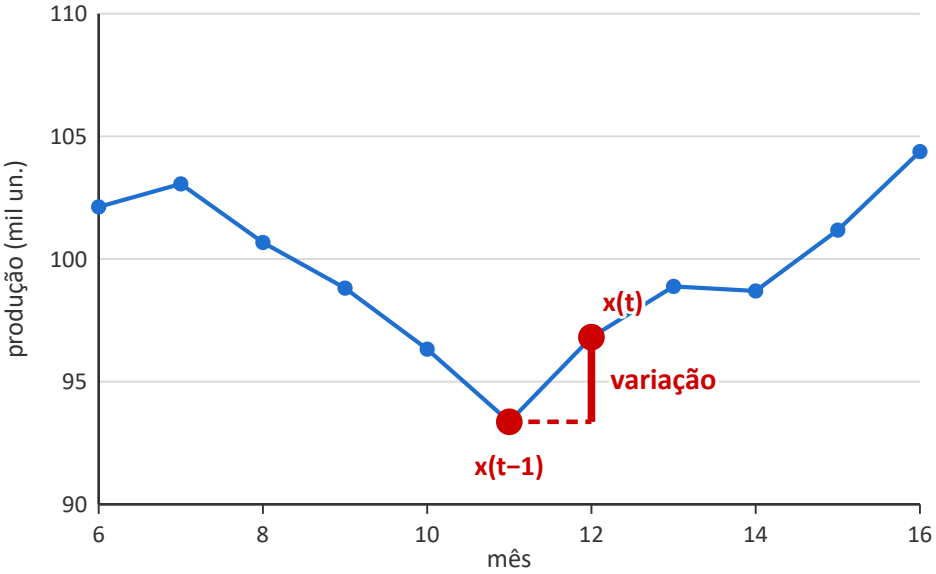
➡️ Cada valor é trocado pela diferença em relação ao **valor anterior**: a **derivada** em versão discreta

$$\Delta x_t = x_t - x_{t-1}$$

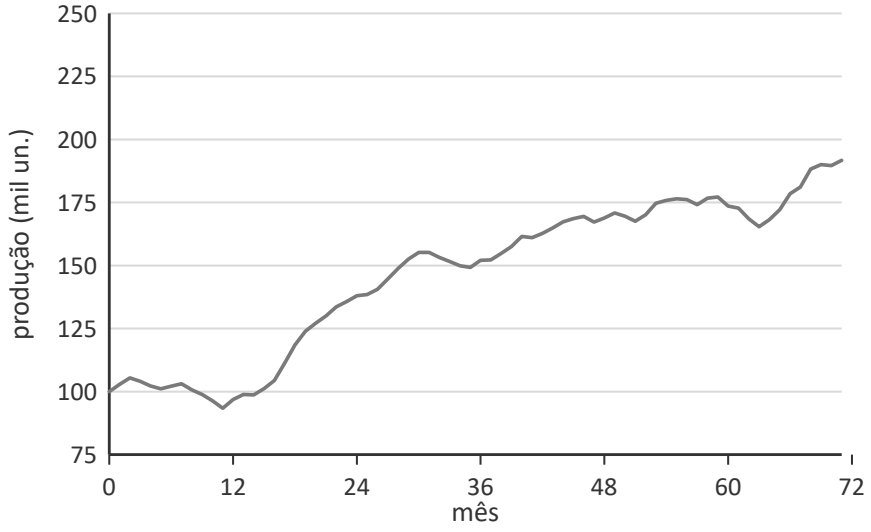
x_t: produção do mês *t*

x_{t-1}: produção do mês anterior

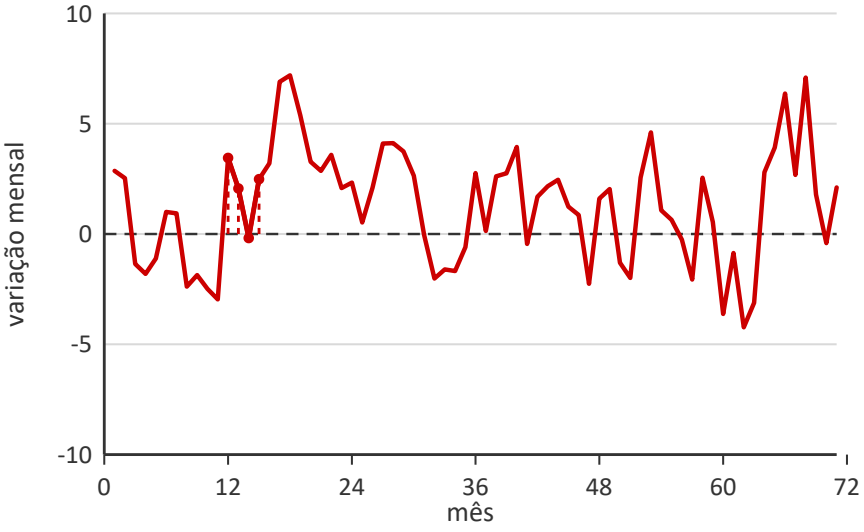
Δ (delta): a variação



Exemplo: diferenciação



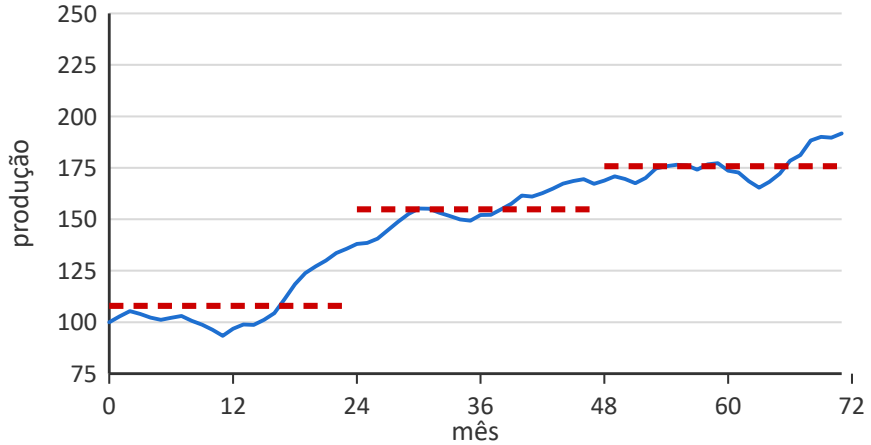
Produção



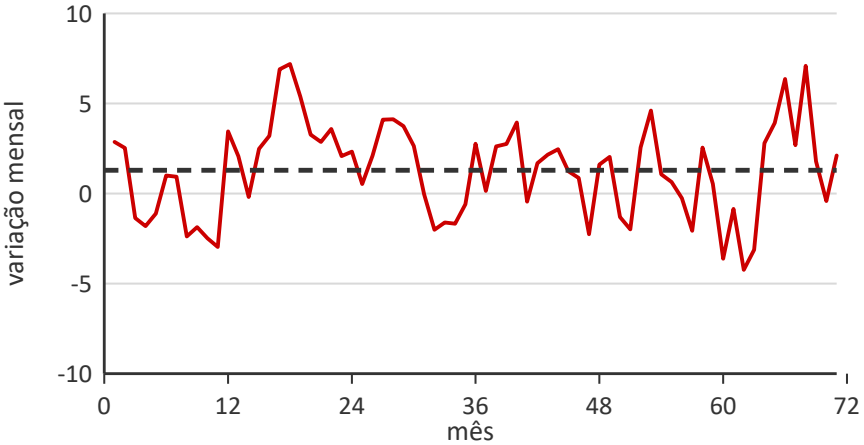
Variação mensal

Ligando os pontos: a **série diferenciada**, que oscila em torno de uma média constante.

Série diferenciada



Antes: série não estacionária
a média sobe com o tempo



Depois: série estacionária
a média fica constante

A série diferenciada pode ser modelada com **AR e MA**.

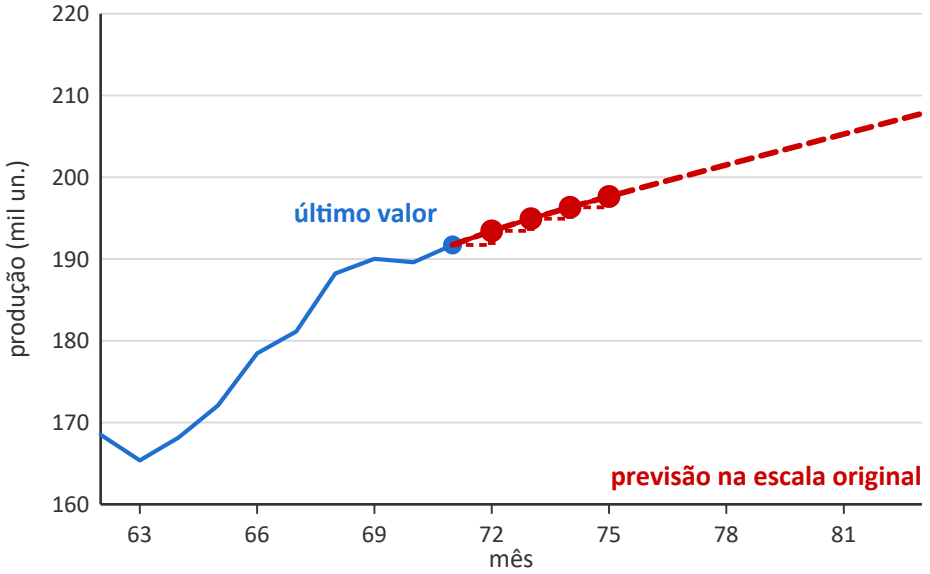
Integração

➡️ **Diferenciar**: do valor para a variação

➡️ **Integrar**: da variação de volta ao valor, **somando** (a integral discreta)

$$x_t = x_{t-1} + \Delta x_t$$

Somando as variações, a previsão volta à **escala original**: milhares de unidades produzidas.



Modelo ARIMA

O que é o ARIMA?

➡️ **ARIMA**: Autorregressivo Integrado de Médias Móveis

➡️ **AR**: o valor depende dos **valores passados** da série

➡️ **I** (integrado): a **diferenciação** que torna a série estacionária

➡️ **MA**: o valor depende dos **erros passados** do modelo

> ARIMA = **AR** + **I** + **MA**: o ARMA da aula passada, com uma etapa de diferenciação.

Etapas do ARIMA

1. Partir da série x_t, **não estacionária**

2. **Diferenciar** *d* vezes

3. **Modelar** AR(*p*) e MA(*q*) na série estacionária

4. **Integrar**: somar de volta as variações

5. Obter a **previsão** na escala original

Parâmetros *p*, *d* e *q*

➡️ ***p*** (parte AR): quantos **valores passados** da série entram

➡️ ***d*** (parte I): quantas vezes **diferenciar**

➡️ ***q*** (parte MA): quantos **erros passados** entram

> Em geral, valores pequenos: **0, 1 ou 2**. O modelo se escreve **ARIMA(*p*, *d*, *q*)**.

Casos particulares

➡️ **ARIMA(0, 1, 0)**: só diferencia. O próximo valor é o **último** mais um erro (sem constante), a previsão **ingênua**

➡️ **ARIMA(1, 0, 0)**: com $d = 0$ é um **AR(1)**, para série já estacionária

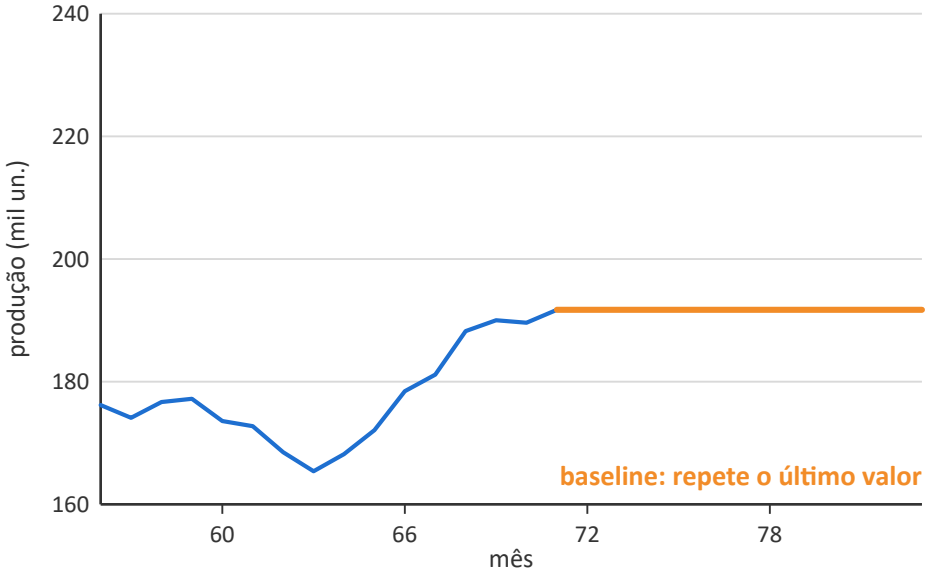
➡️ **ARIMA(0, 0, 1)**: com $d = 0$ é um **MA(1)**

➡️ **ARIMA(1, 1, 0)**: as **variações** da produção seguem um AR(1), o modelo do nosso exemplo

Avaliação no ARIMA

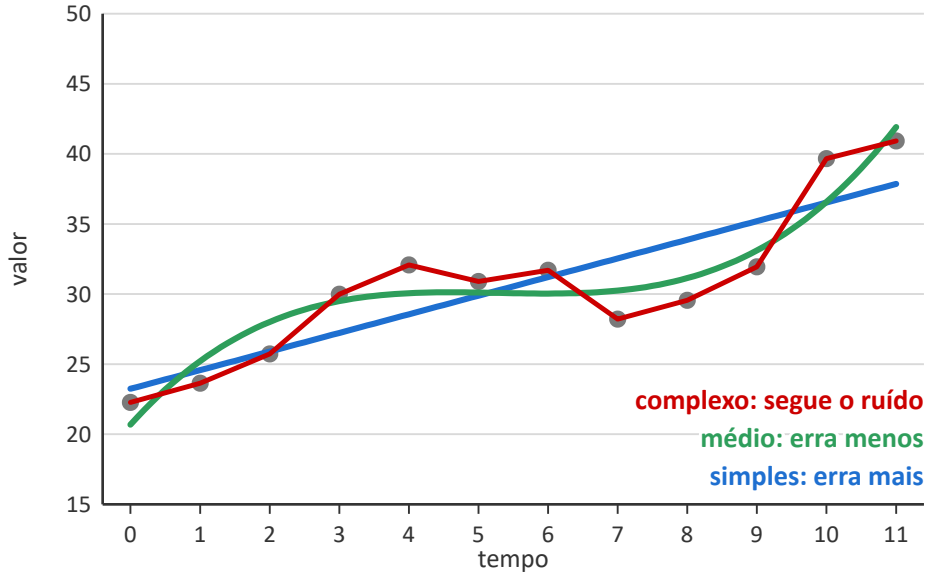
Baseline

- **Baseline**: repete o **último valor**
- Equivale ao ARIMA(0,1,0)
- Régua: o ARIMA precisa ter **erro menor**
- Mesmas métricas e mesmos dados



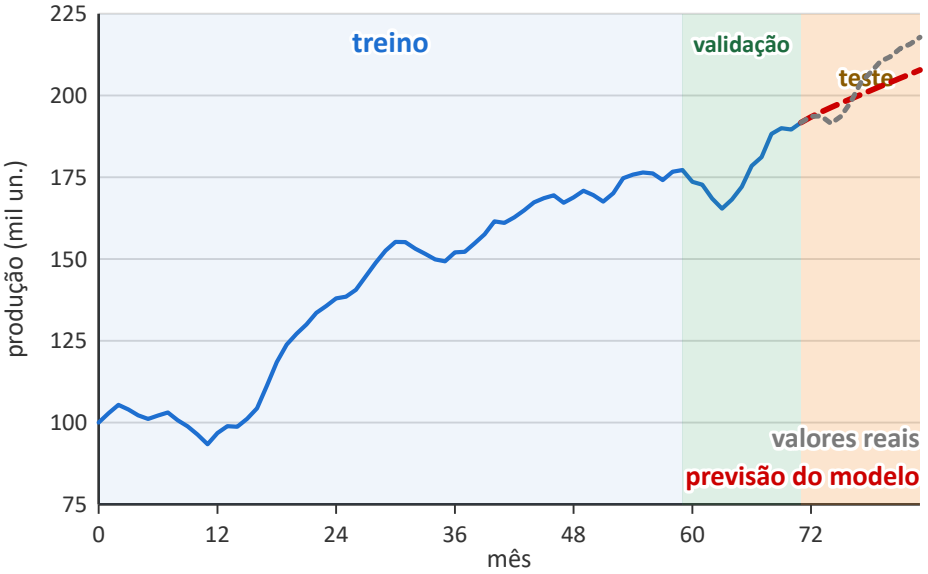
Como escolher o melhor modelo?

- Vários ARIMA(*p*,*d*,*q*) possíveis: **qual escolher**?
- Erro no treino: o **simples** perde para o **médio**
- O **complexo** pode seguir o **ruído**: sobreajuste
- Dados não vistos mostram quem **prevê melhor**



Treino, validação e teste

- Divisão em ordem no tempo: **treino**, **validação** e **teste**
- **Treino**: ajusta cada candidato
- **Validação**: escolhe (*p*, *d*, *q*)
- **Teste**: resultado final, uma única vez



Métricas de erro

MAE

erro absoluto médio

$$\text{MAE} = \text{média dos } |\text{erros}|$$

Todos os erros pesam **igual**

Exemplo
Vendas diárias de uma padaria. Errar 10 pães custa o dobro de errar 5.

RMSE

raiz do erro quadrático médio

$$\text{RMSE} = \sqrt{(\text{ média dos erros}^2)}$$

Erros grandes pesam **mais**

Exemplo
Demanda de energia de uma fábrica. Errar muito no pico causa apagão.

Escolha pela validação

➡️ Cada candidato: ajuste no **treino**, erro na **validação**

➡️ Vence o **menor erro** na métrica definida previamente (MAE ou RMSE)

➡️ Erro parecido: o **mais simples**

➡️ Baseline na mesma métrica: o escolhido precisa ter **erro menor**

➡️ **Teste** uma vez; depois, reajuste com a série inteira

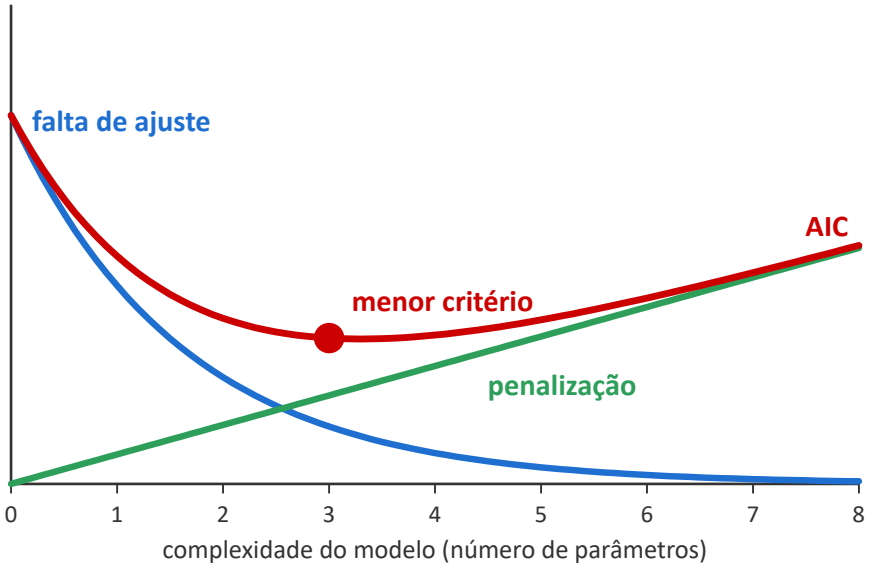
AIC: critério de informação de Akaike

- ➡️ **Falta de ajuste**: cai com mais parâmetros
- ➡️ **Custo**: penalização por parâmetro
- ➡️ **AIC** = falta de ajuste + custo: o **menor** vale mais
- ➡️ Comparar só modelos com o **mesmo *d***

$$\text{AIC} = 2k - 2 \ln L$$

k: número de parâmetros do modelo

L: verossimilhança, o quanto o modelo ajusta os dados



BIC: critério de informação Bayesiano

➡️ **BIC**: a mesma ideia do AIC, **falta de ajuste + custo**

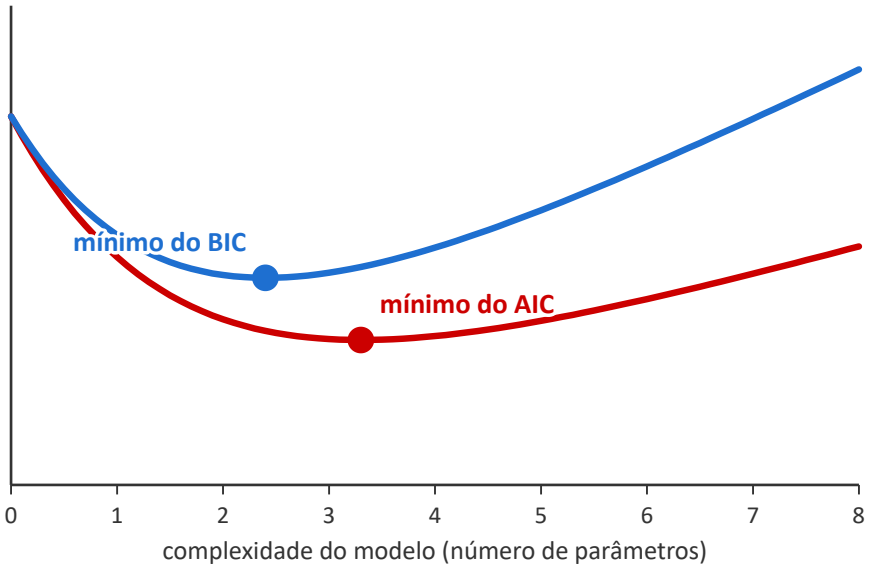
➡️ Custo por parâmetro: **2** no AIC, **ln *n*** no BIC

➡️ Como no AIC: **mesmo *d*** e o **menor** vence

$$\text{BIC} = k \ln n - 2 \ln L$$

k: número de parâmetros; ***n***: número de observações

L: verossimilhança, como no AIC



Validação x AIC/BIC

➡️ **Validação** (MAE e RMSE): erro de previsão em dados não vistos

➡️ **AIC e BIC**: ajuste penalizado, só com dados do ajuste

➡️ Filtram candidatos e servem para séries **mais curtas**

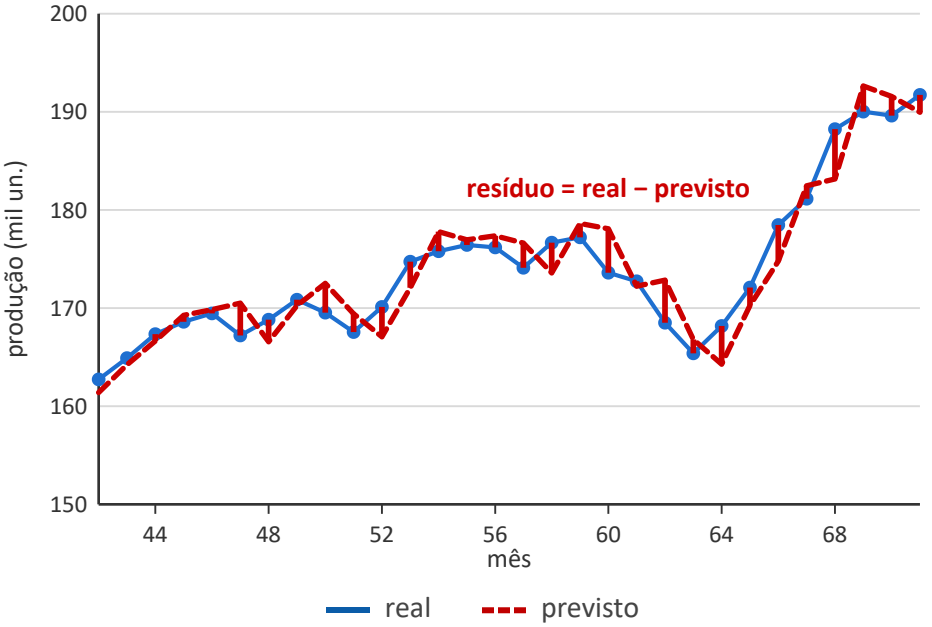
➡️ Um AIC menor **não garante** o menor erro futuro

Ajuste do ARIMA

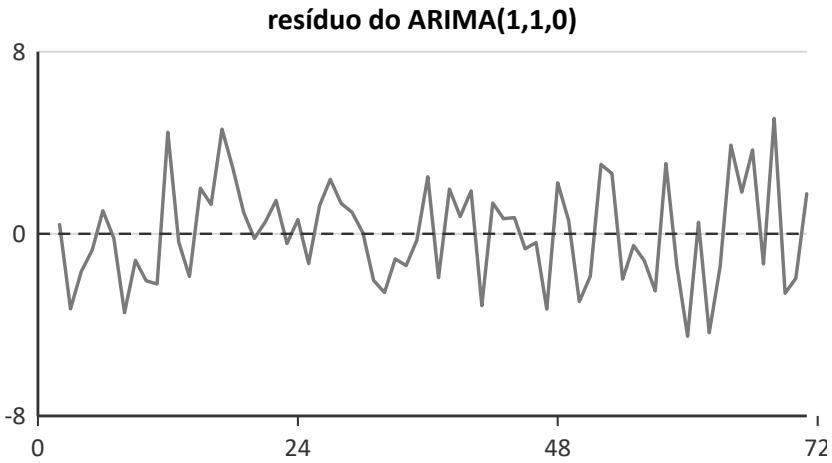
➡️ **Ajustar**: estimar os parâmetros do modelo (ϕ, θ)

➡️ Cada mês recebe uma **previsão de 1 passo**

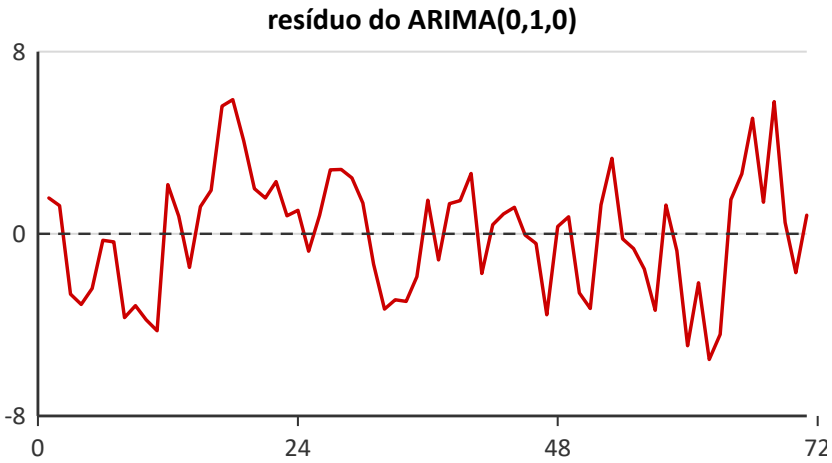
➡️ O que sobra (real menos previsto) é o **resíduo**



Resíduos do modelo



Aleatório: parece ruído
o modelo captou a estrutura



Com padrão: sobrou informação
faltou o AR

Modelo escolhido: **inspecione o resíduo**

Cuidados na escolha do modelo

➡️ Métrica na **série inteira** é otimista

➡️ AIC menor não garante a melhor previsão

➡️ Testar demais vira **pescaria**: modelo que só serve para aquele trecho

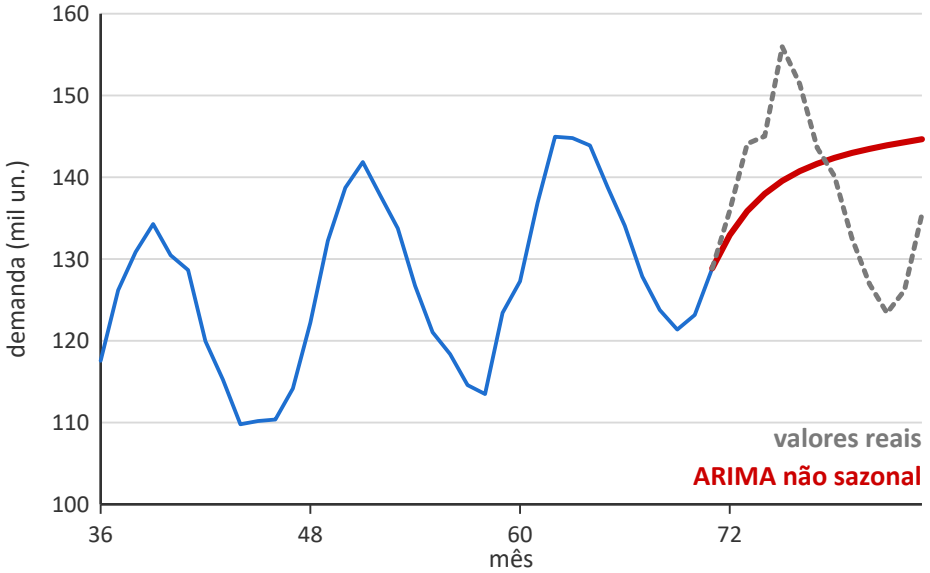
➡️ Conferir o **resíduo** do modelo escolhido

Limites do ARIMA

➡️ **Série com sazonalidade**: demanda com pico a cada ano

➡️ O ARIMA é **não sazonal**

> Com termos sazonais: o **SARIMA**, na próxima aula.



Resumo

➡️ A **diferenciação** remove a tendência; a **integração** volta à escala

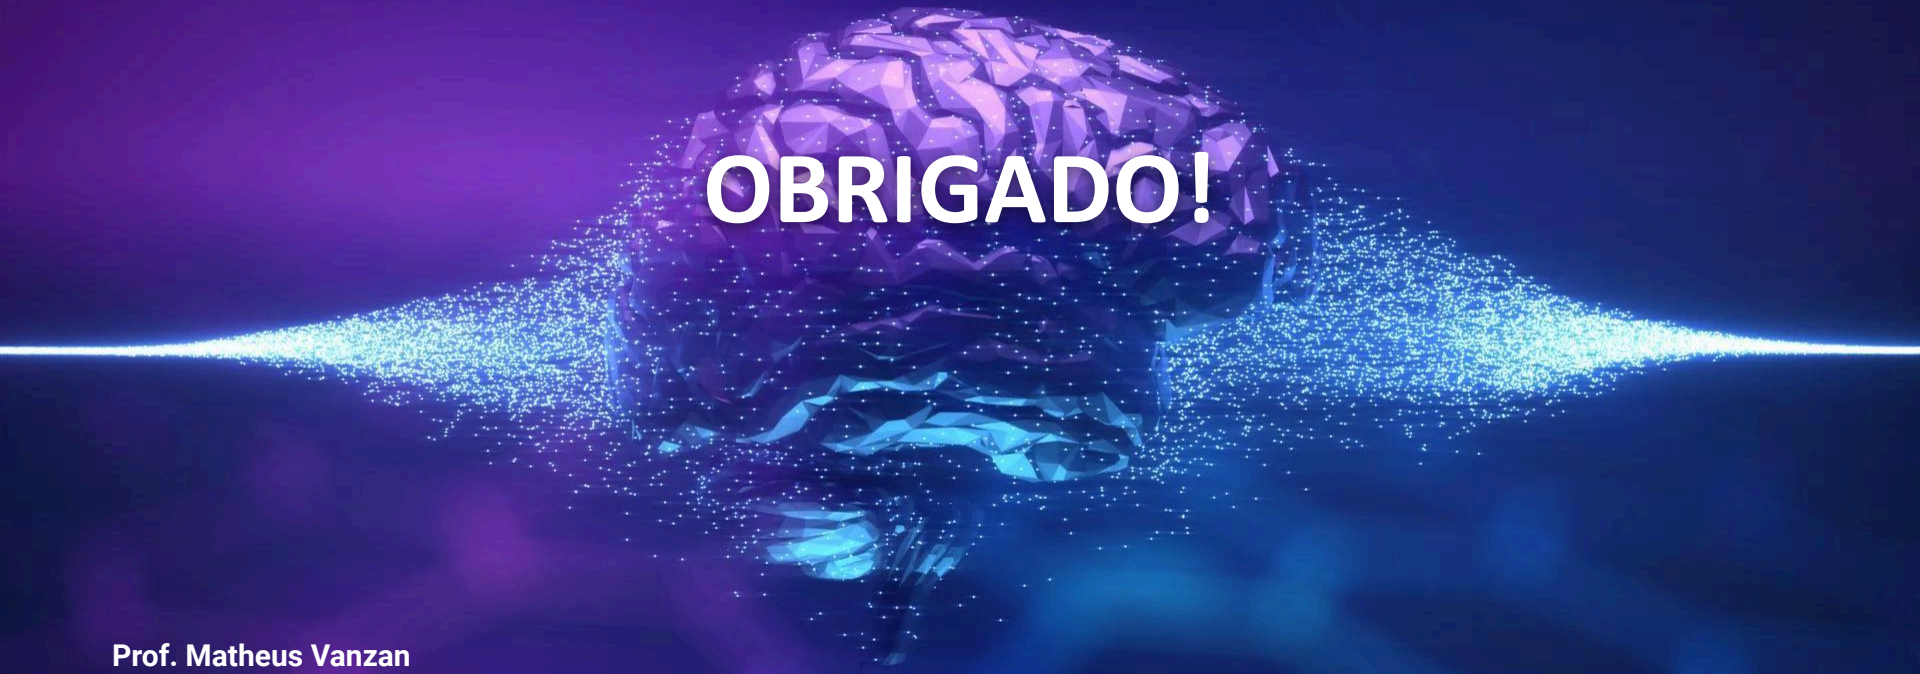
➡️ ARIMA(p,d,q) = **AR**(p) + **I**(d) + **MA**(q)

➡️ Escolha pela **validação** contra o **baseline**; o **teste** confirma

➡️ O **resíduo** deve parecer ruído


MOMENTO DE
PRÁTICA

RESIDÊNCIA
INTELIGÊNCIA ARTIFICIAL



OBRIGADO!

Prof. Matheus Vanzan
matheusvanzan.prof@gmail.com

FIESC UniSENAI INSTITUTO SENAI DE TECNOLOGIA INSTITUTO SENAI DE INOVAÇÃO